

Análisis Estadístico de Datos de Ventas — Cruz Morada

Inferencia y Modelado con procesamiento paralelo

Profesor: Sebastián Salazar Molina — Entrega: 10 de julio de 2026
Semilla de reproducibilidad (CPYD_SEED): 42

Resumen

Se procesaron 3.242.878 transacciones de venta de la cadena Cruz Morada (noviembre 2023 a diciembre 2024, 13 meses, 4 canales de venta y más de 700 locales), aplicando limpieza, detección de outliers, ingeniería de variables y procesamiento paralelo por particiones. Tras la limpieza quedaron 3.242.869 registros válidos (9 descartados por errores de registro, ver sección 2.3). Se validaron 5 hipótesis estadísticas, un modelo de regresión lineal (R^2 ajustado = 0.1639) y un modelo de clustering K-Means (silhouette = 0.4691) sobre la base de clientes.

1. Descripción de la solución implementada

La solución es una aplicación en Python (`analizar_ventas.py`) organizada en el paquete `src/cruz_morada`, con módulos separados para la carga de datos (`carga_datos.py`), procesamiento paralelo (`paralelo/`), preprocesamiento (`preprocesamiento/`), análisis exploratorio (`analisis_exploratorio/`) e inferencia/modelado (`inferencia/`). El archivo CSV se recibe por línea de comandos (`--csv data/ventas_completas.csv.gz`) y puede procesarse por fragmentos (chunking, tamaño configurable) o con Dask para lectura diferida (`--dask`), según el volumen de datos.

El enunciado pide paralelizar las etapas de limpieza, transformación y cálculo de estadísticos. Las tres están implementadas mediante `concurrent.futures.ProcessPoolExecutor` (módulo `paralelo/procesador.py`), que reparte particiones del DataFrame entre varios procesos worker (por defecto `cpu_count() - 1`, ajustable con `--workers`) y mantiene un único pool de procesos vivo durante todo el pipeline, en vez de crear y destruir workers en cada etapa. El cálculo de estadísticos agregados por local (conteo y suma de MONTO APLICADO) siempre corre en paralelo, particionando por LOCAL.

La limpieza y la transformación de variables también están implementadas en paralelo (`--parallel-preprocess`), pero **no se usan en paralelo por defecto**, y esto merece explicarse porque no es una omisión sino una decisión basada en medir, no en suponer. Dos de las variables derivadas (FRECUENCIA COMPRA e ITEMS POR BOLETA) calculan `groupby(CODIGO`

CLIENTE) y `groupby(BOLETA)` internamente; particionar de forma ingenua (por ejemplo por LOCAL o por fecha, como sugiere el enunciado) puede repartir las transacciones de un mismo cliente entre distintos procesos y subestimar esas agregaciones. Por eso, cuando se activa el modo paralelo, la transformación particiona por un hash determinista de CODIGO CLIENTE: como una boleto pertenece siempre a un único cliente, esto garantiza que ningún cliente ni boleto quede repartido entre particiones. La mediana de EDAD usada para imputar valores implausibles también se calcula una sola vez sobre el DataFrame completo y se pasa como constante a cada partición, para no depender de cómo se particionen los datos.

Habiendo resuelto la correctitud, medimos el desempeño real sobre las 3.242.878 filas del dataset completo, y el resultado fue contraintuitivo: la versión secuencial (limpieza + transformación con pandas vectorizado, un solo proceso) tomó $2,84\text{ s} + 4,14\text{ s} \approx 7,0\text{ s}$, mientras que la versión paralela (11 workers) tomó $9,99\text{ s} + 7,07\text{ s} \approx 17,1\text{ s}$ — más de 2 veces más lenta. La razón es que `clean_data` y `create_derived_features` ya son operaciones vectorizadas de pandas (esencialmente bucles en C sobre columnas completas); partirlas en particiones y enviarlas a procesos separados agrega el costo de serializar (pickle) varios cientos de miles de filas por partición y transferirlas entre procesos, un costo que en este caso supera la ganancia de usar más núcleos de CPU. Por eso el pipeline usa procesamiento secuencial vectorizado por defecto para estas dos etapas, y dispone del camino paralelo como una implementación correcta y disponible (`--parallel-preprocess`), documentada y medida, para volúmenes de datos donde el trabajo por partición sea lo suficientemente pesado como para justificar el costo de comunicación entre procesos.

Sobre la decisión de manejo de memoria: con 3.242.878 filas (~217 MB comprimidos), el DataFrame completo cabe en memoria una vez que se descartan las columnas de identificación personal que no se usan en el análisis (NOMBRES, APELLIDOS), por lo que se optó por lectura en chunks que se concatenan en un único DataFrame en memoria, en vez de mantener todo el pipeline fuera de memoria ("out-of-core"). Esto simplifica bastante las operaciones que necesitan ver todos los datos a la vez (correlaciones, regresión, clustering), que de otra forma requerirían un motor distribuido completo. Para volúmenes que ya no quepan en RAM, el flag `--dask` activa lectura lazy con Dask sin cambiar el resto del pipeline. Esta decisión se documenta explícitamente porque durante el desarrollo la máquina disponible tenía recursos limitados (16 GB RAM, ~2,5 GB libres al momento de correr el pipeline completo), lo que fue una restricción real (ver sección 6).

Toda operación con aleatoriedad (imputación, partición train/test 70/30, inicialización de K-Means) usa la semilla fijada por la variable de entorno `CPYD_SEED` (valor por defecto y usado en esta ejecución: 42).

2. Datos y preprocesamiento

2.1 Carga y consolidación

El enunciado describe el CSV con columnas separadas por coma, pero el archivo real (ventas_completas.csv.gz) usa punto y coma (;) como separador y todos los campos entre comillas dobles. El loader detecta automáticamente el separador correcto revisando la primera línea del archivo antes de leerlo con pandas, para que el pipeline no falle interpretando cada fila como una sola columna. Al ser un único archivo consolidado no fue necesario unificar múltiples fuentes.

2.2 Valores faltantes

Se implementó un test aproximado de MCAR (correlación entre indicadores de ausencia de cada columna numérica) y un reporte de nulos por columna. Sobre los 3.242.878 registros (y verificado también con un barrido directo del archivo en busca de campos vacíos o tokens como NULL/NA) no se encontraron valores faltantes explícitos en ninguna columna. Esto difiere del ejemplo del enunciado, que sugería nulos en PORCENTAJE DESCUENTO o FECHA NACIMIENTO, pero es lo que muestra el archivo entregado. El pipeline igualmente conserva la lógica de imputación (mediana para fechas, 0 para descuento, moda para género) por si en algún momento se usa con datos que sí tengan nulos, y el test de MCAR se ejecuta y reporta de todas formas.

2.3 Errores de registro detectados

Se identificaron tres tipos de inconsistencias, distintas a "valores faltantes" pero igual de relevantes para la calidad del análisis:

Problema detectado	Registros afectados	Tratamiento aplicado
BOLETA = 0 (no corresponde a un documento tributario real)	8 de 3.242.878 (<0,001%)	Eliminados
PORCENTAJE DESCUENTO fuera de rango [0,1] (se encontró un registro en 1,17, es decir 117%)	1 registro	Eliminado
EDAD implausible (negativa o mayor a 100 años), originada en FECHA NACIMIENTO corrupta	3.323 (0,10%)	Invalidada e imputada con la mediana de edades plausibles (48,6 años)

Estos casos se interpretan como errores de registro y no como casos de negocio reales: una boleta 0 no existe, un descuento sobre el 100% es imposible, y una edad de -5.944 o 825 años (valores observados antes del tratamiento) no corresponde a ningún cliente real. El umbral [0, 100] años para EDAD se dejó a propósito conservador y queda documentado en el código

(variables_derivadas.py, constantes MIN_EDAD_PLAUSIBLE y MAX_EDAD_PLAUSIBLE).

2.4 Detección de outliers (variables continuas)

Se aplicaron los métodos IQR (rango intercuartílico, factor 1,5) y Z-score (umbral 3) sobre MONTO APLICADO:

Método	Outliers detectados	% del total
IQR (1,5×RIC)	212.493	6,55%
Z-score ($ z >3$)	39.973	1,23%

A diferencia de los errores de la sección 2.3, estos no se eliminan. MONTO APLICADO tiene una distribución fuertemente asimétrica a la derecha (asimetría = 9,06, curtosis = 108,23), y montos altos (hasta \$226.476 CLP) son consistentes con compras de medicamentos de alto costo (tratamientos crónicos, oncológicos, etc.), no con errores de digitación. Se interpretan entonces como casos de negocio reales de cola larga y se conservan en el análisis. UNIDADES no presenta outliers (0% por ambos métodos) por la razón que se explica a continuación.

Hallazgo relevante. UNIDADES es constante e igual a 1 en el 100% de los 3.242.878 registros. Esto revela que el dataset está a nivel de línea de producto por boleta (una fila = un producto distinto comprado), no a nivel de cantidad total. Por lo tanto UNIDADES no aporta varianza para ningún análisis estadístico (correlaciones, regresión, ANOVA), y se documenta así en vez de forzar pruebas degeneradas. Como proxy real del volumen de compra se creó la variable derivada ITEMS POR BOLETA (cantidad de líneas de producto distintas por número de boleta), que sí varía (media = 1,36, máximo = 14) y se usa en su reemplazo en el modelo de regresión y en la hipótesis H2.

2.5 Variables derivadas

Variable	Definición	Media	Nota
MONTO POR UNIDAD	MONTO APLICADO / UNIDADES	\$10.180	Idéntica a MONTO APLICADO (UNIDADES=1 siempre); se mantiene por completitud del enunciado
EDAD	(FECHA – FECHA NACIMIENTO) / 365,25, saneada	49,57 años	3.323 valores implausibles imputados (ver 2.3)

FRECUENCIA COMPRA	Nº de boletas distintas por CODIGO CLIENTE	4,50	Máximo observado: 97 boletas por cliente
ITEMS POR BOLETA	Nº de líneas de producto por BOLETA	1,36	Proxy real de volumen (ver hallazgo de 2.4)
HORA / DIA SEMANA / MES / ANIO / ES_FIN_DE_SEMANA	Extraídas de FECHA	-	Usadas en análisis temporal e hipótesis H3

No se aplicó estandarización a las variables usadas en regresión/ANOVA, para mantener la interpretación directa de los coeficientes en sus unidades originales; sí se estandarizan las variables de clientes antes del clustering (sección 4.3), documentando el scaler ajustado sobre el conjunto de entrenamiento.

3. Análisis exploratorio estadístico

3.1 Estadística descriptiva

Variable	Media	Desv. Est.	Mediana	Asimetría	Curtosis
MONTO APLICADO (CLP)	10.180	14.453	7.662	9,06	108,23
PORCENTAJE DESCUENTO	0.3920	0.1080	0.4000	0.2968	2,85
EDAD (años)	49,57	16,71	48,60	0.2396	-0.7897
ITEMS POR BOLETA	1,36	0.7206	1,00	3,00	14,87

El ticket promedio es de \$10.180 CLP, pero la mediana (\$7.662) es notablemente menor que la media, lo que indica una distribución con cola larga a la derecha: la mayoría de las compras son de monto moderado, pero hay compras puntuales muy altas que "tiran" el promedio hacia arriba (la curtosis de 108,23 muestra una concentración de valores extremos muy superior a una distribución normal). La edad promedio de los clientes es de 49,57 años, con alta dispersión ($\pm 16,71$ años), reflejando una base de clientes heterogénea, típica de una farmacia.

Test de normalidad (Shapiro-Wilk y Kolmogorov-Smirnov)

Variable	Shapiro-Wilk (p)	Kolmogorov-Smirnov (p)	¿Normal?
MONTO APLICADO	$p < 0,0001$	$p < 0,0001$	No
PORCENTAJE DESCUENTO	$p < 0,0001$	$p < 0,0001$	No

Ambas pruebas rechazan la normalidad ($p < 0,0001$) para las dos variables continuas principales. Por eso el pipeline selecciona automáticamente correlación de Spearman (basada en rangos, no asume normalidad) en vez de Pearson para la matriz de correlación general, y cada prueba de hipótesis de comparación de medias verifica normalidad por grupo antes de elegir entre t-test/Welch o Mann-Whitney U.




Figura 1. Distribución de MONTO APLICADO: fuerte asimetría a la derecha, consistente con el rechazo de normalidad.




Figura 2. Distribución de PORCENTAJE DESCUENTO: se concentra en tramos discretos ($\approx 20\%$, 35% , 40% , 50%) en vez de ser continua, lo que sugiere tramos de convenio o copago típicos de farmacias (Fonasa/Isapre) en vez de

descuentos arbitrarios.

3.2 Boxplot por categoría




Figura 3. MONTO APLICADO por CANAL. Las medianas son similares entre canales, pero POS y WEB concentran más valores extremos (mayor volumen de transacciones).

3.3 Matriz de correlación (Spearman) con significancia




Figura 4. UNIDADES aparece en blanco por ser constante (correlación no definida). MONTO APLICADO y PORCENTAJE DESCUENTO muestran correlación positiva moderada.

La correlación de Spearman entre MONTO APLICADO y PORCENTAJE DESCUENTO es de 0.4827 ($p < 0,0001$), es decir, estadísticamente significativa: a mayor monto de compra, mayor tiende a ser el porcentaje de descuento aplicado. Esto es coherente con una lectura de negocio: los tratamientos de mayor valor (crónicos, especialidades) suelen estar cubiertos por convenios con

mayor cobertura porcentual.

3.4 Asociación entre variables categóricas

Prueba	Estadístico	gl	p-value	Conclusión
Chi-cuadrado: CANAL × LOCAL	$\chi^2 = 3.242.869$	2373	$p < 0,0001$	significativo, $p < 0,05$
ANOVA: MONTO APLICADO ~ CANAL	$F = 152,55$	-	$p < 0,0001$	significativo, $p < 0,05$

El canal de venta (POS, WEB, APP, CCT) y el local donde se realiza la compra no son independientes ($p < 0,05$): la mezcla de canales varía significativamente entre locales (algunos locales concentran más ventas WEB/APP, lo cual es esperable si corresponden a zonas con distinto perfil de clientes). El monto promedio de compra también difiere significativamente entre canales (ANOVA, $p < 0,05$), aunque como se ve en el boxplot (Figura 3) las medianas son parecidas y la diferencia la impulsa principalmente la cola de valores altos.

3.5 Patrones temporales

Se agregaron las ventas diarias (suma de MONTO APLICADO por día) sobre el período completo (noviembre 2023 a diciembre 2024) y se aplicó descomposición aditiva (tendencia + estacionalidad + residuo, período = 7 días) y análisis de autocorrelación.




Figura 5. Descomposición de ventas diarias. La venta diaria promedio es de \$84.647.048 CLP ($\pm \$110.230.921$). Se observa una tendencia creciente sostenida durante el período y un fuerte componente estacional semanal superpuesto (picos y valles que se repiten cada 7 días). El día de mayor venta agregada fue el 2024-09-30.




Figura 6. ACF y PACF de la serie diaria. La ACF muestra picos marcados y persistentes en los rezagos múltiplos de 7 (7, 14, 21, 28, 35), confirmando una estacionalidad semanal clara: el nivel de ventas de un día depende fuertemente del nivel del mismo día de la semana anterior. La PACF muestra que, controlando por rezagos intermedios, el rezago 7 sigue siendo el más relevante después del rezago 1.

4. Inferencia estadística

4.1 Pruebas de hipótesis

Se validaron 2 hipótesis del enunciado (H1, H2) y 3 hipótesis propias (H3, H4, H5).

H1 — El ticket promedio en APP es mayor que en WEB (ejemplo del enunciado)

Test: Mann-Whitney U. Media APP = \$10.750, media WEB = \$11.168 ($p = 0,7217$, no significativo, $p \geq 0,05$). Aunque el ticket promedio observado en WEB es numéricamente mayor que en APP, la prueba de Mann-Whitney U indica que esta diferencia no es estadísticamente significativa: no hay evidencia suficiente para afirmar que el canal APP o WEB tenga, por sí solo, un ticket promedio distinto. Es un hallazgo que contradice la premisa del ejemplo del enunciado, y se reporta así porque es lo que muestran los datos reales.

H2 — El % de descuento afecta el volumen de compra (ejemplo del enunciado, adaptado)

Como se explicó en 2.4, UNIDADES es constante y no permite esta prueba tal como está planteada en el enunciado, así que se usa ITEMS POR BOLETA como variable dependiente. Test: regresión lineal simple. Pendiente = 0.0615, $R^2 = 0.000085$ ($p < 0,0001$, significativo, $p < 0,05$). La relación es estadísticamente significativa (con más de 3 millones de registros, hasta efectos diminutos resultan significativos), pero un R^2 de 0.000085 indica que el porcentaje de

descuento explica una fracción prácticamente nula de la variación en ítems por boleta. En términos de negocio, el descuento aplicado no es un predictor relevante del volumen de productos que lleva un cliente en su boleta, aunque la relación exista formalmente.

H3 (propia) — El ticket promedio difiere entre fin de semana y día de semana

Test: Mann-Whitney U. Media fin de semana = \$9.134, media día de semana = \$10.375 ($p < 0,0001$, significativo, $p < 0,05$). El ticket promedio en días de semana es significativamente mayor que en fines de semana. Una lectura de negocio plausible: las compras de mayor valor (tratamientos crónicos, retiro de recetas médicas) se concentran en días hábiles, mientras que el fin de semana concentra compras más pequeñas y espontáneas (por ejemplo analgésicos o cuidado personal).

H4 (propia) — La edad del cliente se correlaciona con el monto de compra

Test: Pearson, aplicado sobre EDAD (cuya distribución es más cercana a la normal que MONTO APLICADO). $r = 0.0495$ ($p < 0,0001$, significativo, $p < 0,05$). Existe una correlación positiva pero muy débil entre la edad del cliente y el monto de compra: los clientes de mayor edad tienden, en promedio, a gastar levemente más, pero la edad por sí sola explica muy poco de la variación del monto (consistente con clientes de mayor edad asociados a tratamientos crónicos de mayor costo, aunque el efecto es marginal frente a otros factores, como el producto específico comprado).

H5 (propia) — El género del cliente influye en el monto promedio de compra

Test: ANOVA one-way. $F = 2.018,31$ ($p < 0,0001$, significativo, $p < 0,05$). Existe una diferencia estadísticamente significativa en el monto promedio de compra entre géneros. El tamaño de la muestra (más de 3 millones de registros) hace que incluso diferencias moderadas resulten altamente significativas, por lo que conviene revisar la magnitud absoluta de la diferencia antes de sacar conclusiones de negocio basadas solo en el p-value.

4.2 Modelado predictivo — Opción A: regresión lineal

Se modeló $\text{MONTO APLICADO} \sim \text{CANAL} + \text{LOCAL} + \text{ITEMS POR BOLETA} + \text{PORCENTAJE DESCUENTO}$ mediante OLS (statsmodels), con partición train/test 70/30 (semilla 42). UNIDADES se sustituyó por ITEMS POR BOLETA por la razón explicada en 2.4: incluir una columna constante en la regresión produce colinealidad perfecta con el intercepto (matriz de diseño no invertible), lo que se detectó en una corrida preliminar (coeficientes idénticos entre intercepto y UNIDADES) y se corrigió antes de la entrega.

Métrica	Valor
R ² ajustado	0.1639

RMSE (test)	\$13.258
MAE (test)	\$6.281

Coeficientes y significancia

Variable	Coeficiente	p-value
Intercepto (canal APP, referencia)	-12.436,3	p < 0,0001
CANAL = CCT	443,8	p = 0,6692
CANAL = POS	1.654,7	p < 0,0001
CANAL = WEB	1.146,9	p < 0,0001
LOCAL	-0.1254	p < 0,0001
ITEMS POR BOLETA	-55,65	p < 0,0001
PORCENTAJE DESCUENTO	54.149,2	p < 0,0001

Diagnóstico de supuestos y multicolinealidad (VIF)

Variable	VIF	Lectura
LOCAL	1,30	Sin problema (VIF < 5)
ITEMS POR BOLETA	3,71	Sin problema (VIF < 5)
PORCENTAJE DESCUENTO	3,83	Sin problema (VIF < 5)

Ningún VIF supera 5, por lo que no hay evidencia de multicolinealidad severa entre los predictores retenidos.

Diagnóstico de linealidad, homocedasticidad y normalidad de residuales




Figura 7. Residuos vs. valores ajustados (muestra de 5.000 puntos del conjunto de entrenamiento). El patrón en forma de abanico, con la dispersión de los residuos creciendo junto con el valor ajustado, es evidencia visual de heterocedasticidad, no de una nube homogénea sin forma como asumiría un modelo bien especificado.




Figura 8. Q-Q plot de los residuos. Los puntos se apartan claramente de la recta de referencia en ambas colas, sobre todo en la cola superior, mostrando una distribución de residuos de cola pesada y asimétrica, no normal.

Test	Supuesto evaluado	Estadístico	p-value	Conclusión
Breusch-Pagan	Homocedasticidad (H0: varianza constante)	208.808,6	$p < 0,0001$	Se rechaza H0: heterocedástico
Jarque-Bera	Normalidad de residuos (H0: distribución normal)	619.743.796,8	$p < 0,0001$	Se rechaza H0: no normales

Los tres supuestos clásicos de OLS quedan comprometidos en algún grado. Sobre linealidad, el gráfico de residuos vs. ajustados (Figura 7) no muestra una curvatura sistemática marcada, pero sí una asimetría hacia residuos positivos grandes, coherente con la cola larga de MONTO APLICADO. El test de Breusch-Pagan rechaza la hipótesis de varianza constante ($p < 0,0001$): el modelo es heterocedástico, es decir, el error de predicción crece junto con el monto de la transacción. El test de Jarque-Bera también rechaza la normalidad de los residuales ($p < 0,0001$, asimetría = 7,52, curtosis = 82,54), consistente con el Q-Q plot (Figura 8).

En la práctica esto significa que los p-values e intervalos de confianza reportados para los coeficientes son aproximados y probablemente subestiman la incertidumbre real, sobre todo para transacciones de monto alto (donde el error es mayor). No invalida las conclusiones cualitativas del modelo (qué variables importan y en qué dirección), pero sí desaconseja usarlo para construir intervalos de predicción precisos sin corregir por heterocedasticidad (por ejemplo, con errores estándar robustos tipo HC3, o modelando $\log(\text{MONTO APLICADO})$ en vez del monto en escala original). Esta limitación es consistente con el R^2 ajustado moderado (0.1639) y con la distribución fuertemente asimétrica de MONTO APLICADO documentada en la sección 3.1; se reporta explícitamente en vez de ocultarse.

El modelo explica solo el 16,4% de la variación del monto de compra. El coeficiente de PORCENTAJE DESCUENTO (+54.149) es, con diferencia, el más influyente: las transacciones con mayor porcentaje de descuento tienden a tener un monto final más alto. Esto no debe leerse como "el descuento causa un mayor gasto", sino como reflejo de que los tratamientos de mayor valor (crónicos, especialidades médicas) suelen tener convenios con mayor cobertura porcentual — la causalidad probablemente va en la dirección opuesta, o es bidireccional. Los canales POS y WEB muestran tickets significativamente más altos que APP (canal de referencia); CCT no muestra diferencia significativa, posiblemente por su bajo volumen de transacciones. LOCAL, al ser un identificador numérico y no una variable de negocio continua, se interpreta con cautela (ver limitaciones).

4.3 Modelado descriptivo — Opción B: clustering de clientes (K-Means)

Se segmentaron los clientes (agrupados por CODIGO CLIENTE) usando 4 variables agregadas: monto total gastado, total de ítems comprados, número de transacciones distintas y descuento promedio recibido, estandarizadas con StandardScaler antes de aplicar K-Means ($k=4$, semilla 42, entrenado sobre partición 70% y evaluado sobre el 100% de los clientes).

Métrica	Valor
Silhouette score	0.4691
Inercia (WCSS)	1.144.994

Clúster	N° de clientes	% del total
0	707.087	59,8%
2	237.196	20,0%
3	210.553	17,8%
1	28.405	2,4%

Un silhouette score de 0.4691 (escala -1 a 1) indica una separación moderada-buena entre los 4 segmentos de clientes: los grupos son razonablemente distinguibles entre sí. El clúster más grande concentra aproximadamente el 60% de los clientes (perfil estándar, bajo gasto/baja frecuencia), mientras que el clúster más pequeño (~2,4%) probablemente corresponde a clientes de alto valor (alta frecuencia y/o alto gasto acumulado), útil para campañas de fidelización dirigidas. Cabe notar que, dado que un porcentaje considerable de CODIGO CLIENTE distintos realiza muy pocas compras (mediana de FRECUENCIA COMPRA = 4), varios clústeres pueden estar dominados por clientes de compra única.

4.4 Validación de modelos y extrapolabilidad

Ambos modelos se evaluaron con partición train/test 70/30 fijada por semilla, siguiendo el enunciado. El error absoluto medio de la regresión (MAE = \$6.281) representa aproximadamente el 62% del ticket promedio, un margen de error considerable para usarlo como predictor puntual de negocio, aunque sigue siendo útil para explicar tendencias agregadas.

¿Es el modelo extrapolable? Con algunos matices importantes:

- Ventana temporal limitada: el dataset cubre 13 meses (noviembre 2023 a diciembre 2024); la tendencia creciente observada (Figura 5) podría no sostenerse indefinidamente y el modelo no la captura explícitamente, ya que no se incluyó un término de tendencia temporal en la regresión.
- Variable de producto omitida: el predictor más obvio del monto de una transacción, qué producto o SKU se compró, no se incluyó en el modelo por su altísima cardinalidad (cientos de SKUs), lo que limita el R^2 alcanzable. Un modelo por categoría de producto probablemente mejoraría bastante el ajuste.
- LOCAL como variable numérica continua: es un identificador, no una magnitud, así que su coeficiente lineal no tiene una interpretación de negocio directa (un modelo con efectos fijos por local, inviable aquí por la cardinalidad mayor a 700, sería más apropiado).
- Sesgo de canal: CCT representa una fracción muy pequeña de las transacciones (canal minoritario), por lo que sus estimaciones son menos confiables que las de POS/WEB/APP.
- El clustering es sensible a la definición de "cliente": con una fracción relevante de compradores de una sola transacción, los clústeres reflejan en parte esa heterogeneidad

estructural más que un comportamiento diferenciado real.

En síntesis, los modelos son útiles como herramientas descriptivas y de apoyo a decisiones agregadas (qué canal o local revisar, qué segmento de clientes priorizar), pero no deberían usarse como predictor puntual de cuánto gastará un cliente específico sin incorporar la variable de producto y una ventana temporal más larga.

5. Justificación de las librerías utilizadas

Librería	Uso en el proyecto
pandas	Carga, limpieza y transformación tabular del dataset completo
NumPy	Operaciones numéricas vectorizadas de soporte
Dask	Lectura diferida (lazy) opcional para volúmenes que excedan la RAM disponible
SciPy (stats)	Pruebas de normalidad (Shapiro-Wilk, KS), correlación (Pearson/Spearman), t-test, Mann-Whitney U, ANOVA, chi-cuadrado
statsmodels	Regresión OLS con fórmulas tipo R, cálculo de VIF, descomposición estacional, ACF/PACF
scikit-learn	K-Means, StandardScaler, train_test_split, métricas (RMSE, MAE, silhouette)
matplotlib / seaborn	Visualizaciones estadísticas (histogramas, boxplots, heatmaps, series de tiempo)
concurrent.futures (librería estándar)	Paralelización real de estadísticos agregados por partición, sin dependencias adicionales

6. Dificultades encontradas y cómo se resolvieron

Dificultad	Cómo se detectó	Resolución
El CSV real usa ; como separador y comillas, no coma como indica el enunciado	Inspección manual de las primeras líneas del archivo descomprimido	Detección automática del separador en <code>carga_datos.py</code> antes de leer con pandas

silhouette_score sin muestreo intentaba calcular una matriz de distancias $O(n^2)$ entre 300 mil o más clientes	Una corrida de prueba con 300 mil filas tardó 13 minutos con uso de CPU casi nulo (señal de swapping de memoria, no de cómputo real)	Se agregó sample_size=10.000 con semilla fija a silhouette_score; la misma corrida bajó a ~21 segundos
UNIDADES constante = 1 en el 100% de los registros reales	Los descriptivos mostraban desviación estándar = 0 y las pruebas devolvían NaN	Se documentó como hallazgo de negocio (dataset a nivel de línea de producto) y se reemplazó por ITEMS POR BOLETA en la regresión y en las hipótesis relacionadas
Edades imposibles (hasta -5.944 y 825 años) por FECHA NACIMIENTO corrupta	Los estadísticos descriptivos mostraban mínimos y máximos absurdos	Se definió un rango plausible [0, 100] años; fuera de rango se invalida y se imputa con la mediana
Incompatibilidad de scipy.stats.kstest con la versión de scipy instalada al pasar args=(media, std) junto al string "norm"	Excepción TypeError en la primera corrida con datos reales	Se reemplazó por una distribución "frozen" (stats.norm(loc=..., scale=...).cdf)
RAM limitada en la máquina de desarrollo (16 GB en total, ~2,5 GB libres)	Monitoreo de memoria disponible antes de la corrida completa	Se descartaron las columnas NOMBRES/APELLIDOS (datos personales no usados en el análisis) en la carga, reduciendo la huella de memoria
Paralelizar limpieza y transformación resultó más lento que la versión secuencial (2,4 veces, ver sección 1), no más rápido como se esperaba inicialmente	Medición directa de tiempos con y sin --parallel-preprocess sobre el dataset completo	Se dejó la ruta secuencial como comportamiento por defecto; la ruta paralela se mantiene disponible, documentada y con particionado correcto (hash de CODIGO CLIENTE), para casos donde el trabajo por partición sea más pesado

7. Rigor metodológico y reproducibilidad

Se usó una semilla única (CPYD_SEED, valor 42) propagada a la imputación, la partición train/test y la inicialización de K-Means. La elección de test estadístico en cada caso se condicionó a la normalidad verificada empíricamente (Shapiro-Wilk), no se asumió a priori. Todo hallazgo negativo (H1 y H2 no soportan la hipótesis del enunciado tal como fue planteada) se reporta explícitamente en vez de omitirse. La ejecución completa es reproducible con: python

`analizar_ventas.py --csv data/ventas_completas.csv.gz` (o `--dask` para lectura diferida), seguido de `python generar_informe.py` para regenerar este informe a partir de `outputs/resultados.json`.

8. Conclusiones

El análisis sobre 3.242.869 transacciones válidas de Cruz Morada confirma la presencia de estacionalidad semanal fuerte en las ventas, diferencias significativas de ticket promedio entre canales y entre días de semana y fin de semana, y una relación moderada entre descuento y monto de compra. El modelo de regresión (R^2 ajustado = 0.1639) y el clustering de clientes (silhouette = 0.4691) ofrecen valor descriptivo para segmentación y priorización comercial, aunque su poder predictivo puntual es limitado por la ausencia de la variable de producto. El hallazgo más relevante para la calidad de los datos —UNIDADES constante y ausencia total de valores nulos explícitos— muestra lo importante que es validar empíricamente los supuestos del enunciado contra los datos reales antes de construir el pipeline de análisis.

Informe generado con `generar_informe.py` a partir de `outputs/resultados.json` (corrida sobre el dataset completo, semilla 42).