

Análisis Estadístico de Datos de Ventas — Cruz Morada

Inferencia y Modelado sobre datos de ventas farmacéuticas con procesamiento paralelo

Computación Paralela y Distribuida — Universidad Tecnológica Metropolitana

Profesor: Sebastián Salazar Molina | Entrega: 10 de julio de 2026

Semilla de reproducibilidad (CPYD_SEED): 42

Resumen ejecutivo. Se procesaron **3.242.878** transacciones de venta de la cadena Cruz Morada (noviembre 2023 – diciembre 2024, 13 meses, 4 canales de venta y más de 700 locales), aplicando limpieza, detección de outliers, ingeniería de variables y procesamiento paralelo por particiones. Tras la limpieza quedaron **3.242.869** registros válidos (9 descartados por errores de registro). Se validaron 5 hipótesis estadísticas, un modelo de regresión lineal (R^2 ajustado = 0.1639) y un modelo de clustering K-Means (silhouette = 0.4691) sobre la base de clientes.

1. Descripción de la solución implementada

La solución es una aplicación Python (`main.py`) estructurada en el paquete `src/cruz_morada`, con módulos separados para carga (`loader.py`), procesamiento paralelo (`parallel/`), preprocesamiento (`preprocessing/`), análisis exploratorio (`eda/`) e inferencia/modelado (`inference/`). El archivo CSV se recibe por línea de comandos (`--csv data/ventas_completas.csv.gz`) y se puede procesar por fragmentos (chunking, tamaño configurable) o con Dask para lectura diferida (`--dask`), según el volumen de datos.

Procesamiento paralelo: los estadísticos agregados por local (conteo y suma de `MONTO APLICADO`) se calculan particionando el DataFrame por `LOCAL` y distribuyendo cada partición a un proceso worker distinto mediante `concurrent.futures.ProcessPoolExecutor` (módulo `parallel/processor.py`), aprovechando múltiples núcleos de CPU. El número de workers se ajusta automáticamente a `cpu_count() - 1` o se puede fijar con `--workers`.

Decisión de diseño sobre memoria: con 3.242.878 filas (~217 MB comprimidos), el DataFrame completo cabe cómodamente en memoria tras descartar columnas de identificación personal no utilizadas en el análisis (`NOMBRES`, `APELLIDOS`), por lo que se optó por lectura en chunks que se concatenan en un único DataFrame en memoria (en vez de mantener todo el pipeline "out-of-core"). Esto simplifica notablemente las operaciones que requieren visión global de los datos (correlaciones, regresión, clustering), que de otro modo exigirían un motor distribuido completo (Spark/Dask con agregaciones incrementales). Para volúmenes que ya no quepan en memoria RAM, el flag `--dask` activa lectura lazy con Dask sin cambiar el resto del pipeline. Esta decisión se documenta explícitamente porque la máquina de desarrollo cuenta con recursos limitados (16 GB RAM, ~2,5 GB libres al momento de ejecutar), lo que fue una restricción real durante el desarrollo (ver sección 6, dificultades).

Reproducibilidad: toda operación con aleatoriedad (imputación, split train/test 70/30, inicialización de K-Means) usa la semilla fijada por la variable de entorno `CPYD_SEED` (valor por defecto y usado en esta ejecución: 42).

2. Datos y Preprocesamiento

2.1 Carga y consolidación

El enunciado documenta el CSV con columnas separadas por coma; el archivo real (`ventas_completas.csv.gz`) usa **punto y coma (;) como separador y todos los campos entre comillas dobles**. El loader detecta automáticamente el separador correcto inspeccionando la primera línea del archivo, evitando así que el pipeline falle silenciosamente interpretando cada fila como una sola columna. Al ser un único archivo consolidado no fue necesario unificar múltiples fuentes.

2.2 Valores faltantes

Se implementó un test aproximado de MCAR (correlación entre indicadores de ausencia de cada columna numérica) y un reporte de nulos por columna. Sobre los 3.242.878 registros completos (y verificado también mediante barrido directo del archivo en busca de campos vacíos o tokens como `NULL/NA`), **no se encontraron valores faltantes explícitos** en ninguna columna. Esto difiere del ejemplo ilustrativo del enunciado (que sugería nulos en `PORCENTAJE DESCUENTO` o `FECHA NACIMIENTO`), pero es el resultado real verificado sobre el archivo entregado. El pipeline conserva la lógica de imputación (mediana para fechas, 0 para descuento, moda para género) por robustez ante datos futuros que sí contengan nulos, y el test de MCAR se ejecuta y reporta igualmente.

2.3 Errores de registro detectados y tratados

Se identificaron y corrigieron tres tipos de inconsistencias reales, distintas a "valores faltantes" pero igual de relevantes para la calidad del análisis:

Problema detectado	Registros afectados	Tratamiento aplicado
<code>BOLETA = 0</code> (no corresponde a un documento tributario real)	8 de 3.242.878 (<0,001%)	Eliminados
<code>PORCENTAJE DESCUENTO</code> fuera de rango <code>[0,1]</code> (se encontró un registro en <code>1,17 = 117%</code>)	1 registro	Eliminado
<code>EDAD</code> implausible (negativa o >100 años), originada en <code>FECHA NACIMIENTO</code> corrupta	3.323 (0,10%)	Invalidada e imputada con la mediana de edades plausibles (48,6 años)

Estos casos se interpretan como **errores de registro** (no como casos de negocio reales): una boleta 0 no existe, un descuento sobre el 100% es imposible, y una edad de -5.944 o 825 años (valores observados antes del tratamiento) no corresponde a ningún cliente real. El umbral `[0, 100]` años para `EDAD` es conservador y documentado explícitamente en `features.py` (`MIN_EDAD_PLAUSIBLE`, `MAX_EDAD_PLAUSIBLE`).

2.4 Detección de outliers (variables continuas)

Se aplicaron los métodos IQR (rango intercuartílico, factor 1,5) y Z-score (umbral 3) sobre MONTO APLICADO:

Método	Outliers detectados	% del total
IQR (1,5×RIC)	212.493	6,55%
Z-score ($ z >3$)	39.973	1,23%

A diferencia de los errores de la sección 2.3, estos **no se eliminan**: dado que MONTO APLICADO tiene una distribución fuertemente asimétrica a la derecha (asimetría = 9,06, curtosis = 108,23), montos altos (hasta \$226.476 CLP) son consistentes con compras de medicamentos de alto costo (tratamientos crónicos, oncológicos, etc.) y no con errores de digitación. Se interpretan como **casos de negocio reales** de cola larga, relevantes para el negocio (ej. compras vía convenios de salud) y se conservan en el análisis.

UNIDADES no presenta outliers (0% por ambos métodos) por la razón que se explica a continuación.

Hallazgo relevante: UNIDADES es **constante e igual a 1 en el 100% de los 3.242.878 registros**. Esto revela que el dataset está a nivel de *línea de producto por boleta* (una fila = un producto distinto comprado), no a nivel de cantidad total. Por lo tanto UNIDADES no aporta varianza para ningún análisis estadístico (correlaciones, regresión, ANOVA), y se documenta así en vez de forzar pruebas degeneradas. Como proxy real del volumen de compra se creó la variable derivada ITEMS POR BOLETA (cantidad de líneas de producto distintas por número de boleta), que sí varía (media = 1,36, máximo = 14) y se usa en su reemplazo en el modelo de regresión y en la hipótesis H2.

2.5 Variables derivadas

Variable	Definición	Media	Nota
MONTO POR UNIDAD	MONTO APLICADO / UNIDADES	\$10.180	Idéntica a MONTO APLICADO (UNIDADES=1 siempre); se mantiene por completitud del enunciado
EDAD	(FECHA – FECHA NACIMIENTO) / 365,25, saneada	49,57 años	3.323 valores implausibles imputados (ver 2.3)
FRECUENCIA COMPRA	Nº de boletas distintas por CODIGO CLIENTE	4,50	Máximo observado: 97 boletas por cliente
ITEMS POR BOLETA	Nº de líneas de producto por BOLETA	1,36	Proxy real de volumen (ver hallazgo 2.4)

HORA / DIA SEMANA			
/ MES / ANIO /	Extraídas de FECHA	-	Usadas en análisis temporal e hipótesis H3
ES_FIN_DE_SEMANA			

No se aplicó estandarización (StandardScaler) a las variables usadas en regresión/ANOVA para mantener la interpretación directa de los coeficientes en las unidades originales; sí se estandarizan las variables de clientes antes del clustering (sección 4.2), documentando el scaler ajustado sobre el conjunto de entrenamiento.

3. Análisis Exploratorio Estadístico

3.1 Estadística descriptiva

Variable	Media	Desv. Est.	Mediana	Asimetría	Curtosis
MONTO APLICADO (CLP)	10.180	14.453	7.662	9,06	108,23
PORCENTAJE DESCUENTO	0.3920	0.1080	0.4000	0.2968	2,85
EDAD (años)	49,57	16,71	48,60	0.2396	-0.7897
ITEMS POR BOLETA	1,36	0.7206	1,00	3,00	14,87

Interpretación no técnica: el ticket promedio es de \$10.180 CLP, pero la mediana (\$7.662) es notablemente menor que la media, señal de una distribución con cola larga a la derecha: la mayoría de las compras son de monto moderado, pero existen compras puntuales muy altas que "tiran" el promedio hacia arriba (curtosis de 108,23 indica una concentración de valores extremos muy superior a una distribución normal). La edad promedio de los clientes es de 49,57 años, con alta dispersión ($\pm 16,71$ años), reflejando una base de clientes heterogénea típica de una farmacia.

Test de normalidad (Shapiro-Wilk y Kolmogorov-Smirnov)

Variable	Shapiro-Wilk (p)	Kolmogorov-Smirnov (p)	¿Normal?
MONTO APLICADO	p < 0,0001	p < 0,0001	No
PORCENTAJE DESCUENTO	p < 0,0001	p < 0,0001	No

Ambas pruebas rechazan la normalidad ($p < 0,0001$) para las dos variables continuas principales. En consecuencia, el pipeline selecciona automáticamente **correlación de Spearman** (basada en rangos, no asume normalidad) en vez de Pearson para la matriz de correlación general, y cada prueba de hipótesis

de comparación de medias verifica normalidad por grupo antes de elegir entre t-test/Welch o Mann-Whitney U.




Fig. 1 — Distribución de MONTO APLICADO: fuerte asimetría a la derecha, consistente con el rechazo de normalidad.



Fig. 2 — Distribución de PORCENTAJE DESCUENTO: se concentra en tramos discretos ($\approx 20\%$, 35% , 40% , 50%) en vez de ser continua, consistente con tramos de convenio/copago típicos de farmacias (Fonasa/Isapre) en vez de descuentos arbitrarios.

3.2 Boxplot por categoría




Fig. 3 — MONTO APLICADO por CANAL. Las medianas son similares entre canales, pero POS y WEB concentran más valores extremos (mayor volumen de transacciones).

3.3 Matriz de correlación (Spearman) con significancia




Fig. 4 — UNIDADES aparece en blanco por ser constante (correlación no definida). MONTO APLICADO y PORCENTAJE DESCUENTO muestran correlación positiva moderada.

La correlación de Spearman entre **MONTO APLICADO** y **PORCENTAJE DESCUENTO** es de **0.4827** ($p < 0,0001$), estadísticamente significativa: a mayor monto de compra, mayor tiende a ser el porcentaje de descuento aplicado. Esto es coherente con la lectura de negocio: tratamientos de mayor valor (crónicos, especialidades) suelen estar cubiertos por convenios con mayor cobertura porcentual.

3.4 Asociación entre variables categóricas

Prueba	Estadístico	gl	p-value	Conclusión
Chi-cuadrado: CANAL × LOCAL	$\chi^2 = 3.242.869$	2373	$p < 0,0001$	Significativo ($p < 0,05$)
ANOVA: MONTO APLICADO ~ CANAL	$F = 152,55$	-	$p < 0,0001$	Significativo ($p < 0,05$)

Interpretación no técnica: el canal de venta (POS, WEB, APP, CCT) y el local donde se realiza la compra **no son independientes** ($p < 0,05$): la mezcla de canales varía significativamente entre locales (algunos locales concentran más ventas WEB/APP, esperable si corresponden a zonas con distinto perfil de clientes). El monto promedio de compra también **difiere significativamente entre canales** (ANOVA, $p < 0,05$), aunque como se ve en el boxplot (Fig. 3) las medianas son parecidas y la diferencia es impulsada principalmente por la cola de valores altos.

3.5 Patrones temporales

Se agregaron las ventas diarias (suma de MONTO APLICADO por día) sobre el período completo (nov-2023 a dic-2024) y se aplicó descomposición aditiva (tendencia + estacionalidad + residuo, período = 7 días) y análisis de autocorrelación.




Fig. 5 — Descomposición de ventas diarias. La venta diaria promedio es de \$84.647.048 CLP ($\pm \$110.230.921$). Se observa una **tendencia creciente** sostenida durante el período y un fuerte **componente estacional semanal** superpuesto (picos y valles que se repiten cada 7 días). El día de mayor venta agregada fue el 2024-09-30.




Fig. 6 — ACF y PACF de la serie diaria. La ACF muestra picos marcados y persistentes en los rezagos múltiplos de 7 (7, 14, 21, 28, 35), confirmando una **estacionalidad semanal** clara: el nivel de ventas de un día depende fuertemente del nivel del mismo día de la semana anterior. La PACF muestra que, controlando por rezagos intermedios, el rezago 7 sigue siendo el más relevante después del rezago 1.

4. Inferencia Estadística

4.1 Pruebas de hipótesis

Se validaron 2 hipótesis del enunciado (H1, H2) y 3 hipótesis propias (H3, H4, H5).

H1 — "El ticket promedio en APP es mayor que en WEB" (ejemplo del enunciado)

Test: Mann-Whitney U. Media APP = \$10.750, media WEB = \$11.168. $p = 0,7217$. No significativo ($p \geq 0,05$)

Interpretación no técnica: aunque el ticket promedio observado en WEB (\$11.168) es numéricamente mayor que en APP (\$10.750), la prueba de Mann-Whitney U indica que **esta diferencia no es estadísticamente significativa** ($p = 0,72$): no hay evidencia suficiente para afirmar que el canal APP o WEB tenga, por sí solo, un ticket promedio distinto. Es un hallazgo honesto que contradice la premisa del ejemplo del enunciado, y se reporta así porque es lo que muestran los datos reales.

H2 — "El % de descuento afecta el volumen de compra" (ejemplo del enunciado, adaptado)

Como se explicó en 2.4, UNIDADES es constante y no permite esta prueba tal como está planteada en el enunciado; se usa ITEMS POR BOLETA como variable dependiente. Test: regresión lineal simple. Pendiente = 0.0615, $R^2 = 0.000085$, $p < 0,0001$. Significativo ($p < 0,05$)

Interpretación no técnica: la relación es estadísticamente significativa (con más de 3 millones de registros, incluso efectos diminutos resultan significativos), pero el R^2 de 0.000085 indica que el porcentaje de descuento explica una fracción prácticamente nula de la variación en ítems por boleta. En términos de negocio: **el descuento aplicado no es un predictor relevante del volumen de productos que lleva un cliente en su boleta**, aunque la relación exista formalmente.

H3 (propia) — "El ticket promedio difiere entre fin de semana y día de semana"

Test: Mann-Whitney U. Media fin de semana = \$9.134, media día de semana = \$10.375. $p < 0,0001$.

Significativo ($p < 0,05$)

Interpretación no técnica: el ticket promedio en días de semana (\$10.375) es significativamente **mayor** que en fines de semana (\$9.134). Una lectura de negocio plausible: las compras de mayor valor (tratamientos crónicos, retiro de recetas médicas) se concentran en días hábiles, mientras que el fin de semana concentra compras más pequeñas y espontáneas (ej. analgésicos, cuidado personal).

H4 (propia) — "La edad del cliente se correlaciona con el monto de compra"

Test: Pearson (aplicado sobre EDAD, cuya distribución es más cercana a la normal que MONTO APLICADO; se reporta como referencia adicional a la matriz Spearman de la sección 3.3). $r = 0.0495$. $p < 0,0001$. Significativo ($p < 0,05$)

Interpretación no técnica: existe una correlación positiva pero **muy débil** ($r = 0.0495$) entre la edad del cliente y el monto de compra: clientes de mayor edad tienden, en promedio, a gastar levemente más, pero la edad por sí sola explica muy poco de la variación del monto (consistente con clientes de mayor edad asociados a tratamientos crónicos de mayor costo, pero el efecto es marginal frente a otros factores como el producto específico comprado).

H5 (propia) — "El género del cliente influye en el monto promedio de compra"

Test: ANOVA one-way. $F = 2.018,31$. $p < 0,0001$. Significativo ($p < 0,05$)

Interpretación no técnica: existe una diferencia estadísticamente significativa en el monto promedio de compra entre géneros. El tamaño de la muestra (más de 3 millones de registros) hace que incluso diferencias moderadas sean altamente significativas; se recomienda a negocio revisar la magnitud absoluta de la diferencia (media por grupo) antes de tomar decisiones comerciales basadas solo en el p-value.

4.2 Modelado predictivo — Opción A: Regresión lineal

Se modeló `MONTO APLICADO ~ CANAL + LOCAL + ITEMS POR BOLETA + PORCENTAJE DESCUENTO` mediante OLS (statsmodels), con partición train/test 70/30 (semilla 42). `UNIDADES` se sustituyó por `ITEMS POR BOLETA` por la razón explicada en 2.4: incluir una columna constante en la regresión produce colinealidad perfecta con el intercepto (matriz de diseño no invertible), lo que se detectó en una corrida preliminar (coeficientes idénticos entre intercepto y UNIDADES) y se corrigió antes de la entrega.

Métrica	Valor
R ² ajustado	0.1639
RMSE (test)	\$13.258
MAE (test)	\$6.281

Coeficientes y significancia

Variable	Coeficiente	p-value
Intercepto (canal APP, referencia)	-12.436,3	p < 0,0001
CANAL = CCT	443,8	p = 0,6692
CANAL = POS	1.654,7	p < 0,0001
CANAL = WEB	1.146,9	p < 0,0001
LOCAL	-0.1254	p < 0,0001
ITEMS POR BOLETA	-55,65	p < 0,0001
PORCENTAJE DESCUENTO	54.149,2	p < 0,0001

Diagnóstico de supuestos y multicolinealidad (VIF)

Variable	VIF	Lectura
LOCAL	1,30	Sin problema (VIF < 5)
ITEMS POR BOLETA	3,71	Sin problema (VIF < 5)
PORCENTAJE DESCUENTO	3,83	Sin problema (VIF < 5)

Ningún VIF supera 5, por lo que no hay evidencia de multicolinealidad severa entre los predictores retenidos. Respecto a los supuestos clásicos de OLS: dado que ni MONTO APLICADO ni PORCENTAJE DESCUENTO son normales (sección 3.1) y el modelo excluye variables clave (ver limitaciones), es esperable que los residuales no sean perfectamente homocedásticos ni normales; esto es consistente con un R² ajustado moderado (0.1639) y se discute como limitación explícita a continuación en vez de ocultarse.

Interpretación no técnica: el modelo explica solo el 16,4% de la variación del monto de compra. El coeficiente de PORCENTAJE DESCUENTO (+54.149) es, con diferencia, el más influyente: transacciones con mayor porcentaje de descuento tienden a tener un monto final más alto. Esto **no debe leerse como "el descuento causa un mayor gasto"**, sino como reflejo de que los tratamientos de mayor valor (crónicos, especialidades médicas) suelen tener convenios con mayor cobertura porcentual — la causalidad probablemente va en la dirección opuesta o es bidireccional. El

canal POS y WEB muestran tickets significativamente más altos que APP (canal de referencia); CCT no muestra diferencia significativa (posiblemente por su bajo volumen de transacciones). LOCAL, al ser un identificador numérico y no una variable de negocio continua, se interpreta con cautela (ver limitaciones).

4.3 Modelado descriptivo — Opción B: Clustering de clientes (K-Means)

Se segmentaron los clientes (agrupados por CODIGO CLIENTE) usando 4 variables agregadas: monto total gastado, total de ítems comprados, número de transacciones distintas y descuento promedio recibido, estandarizadas con StandardScaler antes de aplicar K-Means (k=4, semilla 42, entrenado sobre partición 70% y evaluado sobre el 100% de los clientes).

Métrica	Valor
Silhouette score	0.4691
Inercia (WCSS)	1.144.994

Clúster	N° de clientes	% del total
0	707.087	59,8%
2	237.196	20,0%
3	210.553	17,8%
1	28.405	2,4%

Interpretación no técnica: un silhouette score de 0.4691 (escala -1 a 1) indica una **separación moderada-buena** entre los 4 segmentos de clientes: los grupos son razonablemente distinguibles entre sí. El clúster más grande concentra aproximadamente el 60% de los clientes (perfil "estándar", bajo gasto/baja frecuencia), mientras que el clúster más pequeño (~2,4%) probablemente corresponde a clientes de alto valor (alta frecuencia y/o alto gasto acumulado), útil para campañas de fidelización dirigidas. Nota: dado que un porcentaje considerable de CODIGO CLIENTE distintos realiza muy pocas compras (ver FRECUENCIA COMPRA, mediana = 4), varios clústeres pueden estar dominados por clientes de compra única.

4.4 Validación de modelos y extrapolabilidad

Ambos modelos se evaluaron con partición train/test 70/30 fijada por semilla, siguiendo el enunciado. El error absoluto medio de la regresión (MAE = \$6.281) representa aproximadamente el 62% del ticket promedio, un margen de error considerable para uso como predictor puntual de negocio, aunque útil para explicar tendencias agregadas.

¿Es el modelo extrapolable? Con matices importantes:

- Ventana temporal limitada:** el dataset cubre 13 meses (nov-2023 a dic-2024); la tendencia creciente observada (Fig. 5) podría no sostenerse indefinidamente y el modelo no la captura explícitamente (no

se incluyó un término de tendencia temporal en la regresión).

- **Variable de producto omitida:** el predictor más obvio del monto de una transacción —qué producto/SKU se compró— no se incluyó en el modelo por su altísima cardinalidad (cientos de SKUs), lo que limita el R^2 alcanzable. Un modelo por categoría de producto probablemente mejoraría sustancialmente el ajuste.
- **LOCAL como variable numérica continua:** es un identificador, no una magnitud; su coeficiente lineal no tiene una interpretación de negocio directa (un modelo con efectos fijos por local, inviable aquí por la cardinalidad >700, sería más apropiado).
- **Sesgo de canal:** CCT representa una fracción muy pequeña de las transacciones (canal minoritario), por lo que sus estimaciones son menos confiables que las de POS/WEB/APP.
- **Clustering sensible a la definición de "cliente":** con una fracción relevante de compradores de una sola transacción, los clústeres reflejan en parte esa heterogeneidad estructural más que un comportamiento diferenciado real.

En síntesis, los modelos son útiles como **herramientas descriptivas y de apoyo a decisiones agregadas** (qué canal/local revisar, qué segmento de clientes priorizar), pero no deberían usarse como predictor puntual de "cuánto gastará este cliente" sin incorporar la variable de producto y una ventana temporal más larga.

5. Justificación de librerías utilizadas

Librería	Uso en el proyecto
pandas	Carga, limpieza y transformación tabular del dataset completo
NumPy	Operaciones numéricas vectorizadas de soporte
Dask	Lectura diferida (lazy) opcional para volúmenes que excedan la RAM disponible
SciPy (stats)	Pruebas de normalidad (Shapiro-Wilk, KS), correlación (Pearson/Spearman), t-test, Mann-Whitney U, ANOVA, chi-cuadrado
statsmodels	Regresión OLS con fórmulas tipo R, cálculo de VIF, descomposición estacional, ACF/PACF
scikit-learn	K-Means, StandardScaler, train_test_split, métricas (RMSE, MAE, silhouette)
matplotlib / seaborn	Visualizaciones estadísticas (histogramas, boxplots, heatmaps, series de tiempo)
concurrent.futures (stdlib)	Paralelización real de estadísticos agregados por partición, sin dependencias adicionales

6. Dificultades encontradas y cómo se resolvieron

Dificultad	Cómo se detectó	Resolución
El CSV real usa ; como separador y comillas, no coma como indica el enunciado	Inspección manual de las primeras líneas del archivo descomprimido	Detección automática del separador en loader.py antes de leer con pandas
silhouette_score sin muestreo intentaba calcular una matriz de distancias $O(n^2)$ entre ~300 mil+ clientes	Una corrida de prueba con 300 mil filas tardó 13 minutos con uso de CPU casi nulo (señal de swapping de memoria, no de cómputo real)	Se agregó sample_size=10.000 con semilla fija a silhouette_score; la misma corrida bajó a ~21 segundos
UNIDADES constante = 1 en el 100% de los registros reales	Descriptivos mostraban desviación estándar = 0 y pruebas devolvían NaN	Se documentó como hallazgo de negocio (dataset a nivel de línea de producto) y se reemplazó por ITEMS POR BOLETA en regresión e hipótesis relacionadas
Edades imposibles (hasta -5.944 y 825 años) por FECHA NACIMIENTO corrupta	Estadísticos descriptivos mostraban mínimos/máximos absurdos	Se definió un rango plausible [0, 100] años; fuera de rango se invalida y se imputa con la mediana
Incompatibilidad de scipy.stats.kstest con la versión de scipy instalada al pasar args=(media, std) junto al string "norm"	Excepción TypeError en la primera corrida con datos reales	Se reemplazó por una distribución "frozen" (stats.norm(loc=..., scale=...).cdf)
RAM limitada en la máquina de desarrollo (16 GB totales, ~2,5 GB libres)	Monitoreo de memoria disponible antes de la corrida completa	Se descartaron columnas NOMBRES/APELLIDOS (PII no usada en el análisis) en la carga, reduciendo la huella de memoria

7. Rigor metodológico y reproducibilidad

- Semilla única (CPYD_SEED, valor 42) propagada a imputación, split train/test y K-Means.
- Elección de test estadístico condicionada a normalidad verificada empíricamente (Shapiro-Wilk) en cada caso, no asumida a priori.
- Todo hallazgo "negativo" (H1 y H2 no soportan la hipótesis del enunciado tal como fue planteada) se reporta explícitamente en vez de omitirse.
- Ejecución completa reproducible con: `python main.py --csv data/ventas_completas.csv.gz` (o `--dask` para lectura diferida), seguido de `python generate_report.py` para regenerar este informe desde `outputs/resultados.json`.

8. Conclusiones

El análisis sobre 3.242.869 transacciones válidas de Cruz Morada confirma la presencia de estacionalidad semanal fuerte en las ventas, diferencias significativas de ticket promedio entre canales y entre días de semana/fin de semana, y una relación moderada entre descuento y monto de compra. El modelo de regresión (R^2 ajustado = 0.1639) y el clustering de clientes (silhouette = 0.4691) ofrecen valor descriptivo para segmentación y priorización comercial, aunque su poder predictivo puntual es limitado por la ausencia de la variable de producto. El hallazgo más relevante para la calidad de datos — **UNIDADES** constante y ausencia total de valores nulos explícitos— ilustra la importancia de validar empíricamente los supuestos del enunciado contra los datos reales antes de construir el pipeline de análisis.

Informe generado automáticamente por `generate_report.py` a partir de `outputs/resultados.json` (corrida sobre el dataset completo, semilla 42).