



Universidad Tecnológica Metropolitana
Departamento de Computación e Informática

Análisis Estadístico de Datos de Ventas

Inferencia y Modelado

Cruz Morada S.A.

Integrantes: Paz Pérez Avaria
Rodrigo Ureta Veloso

Profesor: Sebastián Salazar Molina

Fecha de entrega: 10 de julio de 2026

Semilla (CPYD_SEED): 7

Índice

Resumen Ejecutivo	3
1. Descripción de la Solución Implementada	4
1.1. Arquitectura del Sistema	4
1.2. Procesamiento Paralelo	4
1.3. Reproducibilidad	5
2. Datos y Preprocesamiento	5
2.1. Carga y Consolidación	6
2.2. Valores Faltantes	6
2.3. Errores de Registro Detectados	7
2.4. Detección de Valores Atípicos	7
2.5. Variables Derivadas	8
3. Análisis Exploratorio Estadístico	9
3.1. Estadística Descriptiva	9
3.2. Tests de Normalidad	10
3.3. Distribución de Variables	10
3.4. Boxplot por Canal de Venta	13
3.5. Matriz de Correlación (Spearman)	14
3.6. Análisis de Asociación entre Variables Categóricas	15
3.7. Patrones Temporales	16
3.8. Distribución por Hora del Día	18
3.9. Distribución por Género	19
4. Inferencia Estadística	19
4.1. Pruebas de Hipótesis	20
4.1.1. H1 — Ticket promedio APP versus WEB	20
4.1.2. H2 — Porcentaje de descuento y volumen de compra	20
4.1.3. H3 — Ticket promedio en fin de semana versus día de semana	21
4.1.4. H4 — Edad del cliente y monto de compra	22
4.1.5. H5 — Género del cliente y monto promedio de compra	22
4.2. Resumen de Hipótesis	23
5. Modelado Predictivo y Descriptivo	23
5.1. Modelo de Regresión Lineal (Opción A)	23
5.1.1. Formulación del modelo	23
5.1.2. Métricas de ajuste	24
5.1.3. Coeficientes e interpretación	24
5.1.4. Detección de multicolinealidad (VIF)	25
5.1.5. Diagnóstico de supuestos	25
5.2. Modelo de Clustering K-Means (Opción B)	26

5.2.1. Construcción del modelo	26
5.2.2. Elección del número de clústeres	27
5.2.3. Métricas de validación	27
5.2.4. Perfil de cada clúster	28
5.2.5. Extrapolabilidad y limitaciones del modelo	28
6. Justificación de Técnicas y Librerías	29
6.1. Justificación de las Técnicas Estadísticas	29
6.1.1. Detección de outliers: IQR y Z-score en lugar de DBSCAN	29
6.1.2. Selección automática entre Pearson/Spearman y t-test/Mann-Whitney	29
6.1.3. Chi-cuadrado para asociación entre variables categóricas	29
6.1.4. Regresión OLS en lugar de modelos de árboles o regularización	30
6.1.5. K-Means en lugar de clustering jerárquico o DBSCAN	30
6.1.6. Breusch-Pagan y Jarque-Bera para diagnóstico de la regresión	30
6.1.7. Partición train/test 70/30 con semilla fija	30
6.2. Justificación de las Librerías Utilizadas	31
7. Dificultades Encontradas y Soluciones	33
7.1. Separador incorrecto en el archivo CSV	33
7.2. Cálculo de silhouette score inviable sin muestreo	33
7.3. Variable UNIDADES constante en todo el dataset	33
7.4. Edades implausibles por fechas de nacimiento corruptas	34
7.5. Incompatibilidad de scipy.stats.kstest	34
7.6. Procesamiento paralelo más lento que el secuencial	35
7.7. Restricción de memoria en la máquina de desarrollo	35
8. Conclusiones	35
8.1. Hallazgos Principales	36
8.2. Sobre el Modelo de Regresión	37
8.3. Sobre el Procesamiento Paralelo	37
8.4. Reflexión Final	37
9. Bibliografía	38

Resumen Ejecutivo

El presente informe documenta el análisis estadístico realizado sobre los datos de ventas de la cadena de farmacias Cruz Morada, correspondientes al período comprendido entre noviembre de 2023 y diciembre de 2024, abarcando un total de 13 meses de operación continua en más de 700 locales distribuidos a lo largo de Chile y a través de 4 canales de venta distintos: POS, WEB, APP y CCT.

El volumen de datos procesado asciende a **3.242.878 transacciones**, de las cuales **3.242.869 fueron consideradas válidas** tras el proceso de limpieza y validación. Los 9 registros descartados corresponden a errores de registro documentados, tales como boletas con folio cero, porcentajes de descuento fuera del rango permitido y fechas de nacimiento incoherentes con edades plausibles.

El análisis se estructuró en tres grandes etapas. En primer lugar, se realizó un proceso de preprocesamiento que incluyó la detección y tratamiento de valores atípicos, la creación de variables derivadas con valor analítico y la validación de la integridad del dataset. En segundo lugar, se llevó a cabo un análisis exploratorio estadístico que abarcó medidas de tendencia central y dispersión, pruebas de normalidad, análisis de correlación, estudio de patrones temporales y distribución por canal. En tercer lugar, se desarrolló una etapa de inferencia estadística que comprende la validación de cinco hipótesis, la construcción de un modelo de regresión lineal y la segmentación de clientes mediante clustering K-Means.

Entre los hallazgos más relevantes se destaca que el canal POS concentra el **96,19 %** de las transacciones, evidenciando que la venta presencial sigue siendo el canal dominante a pesar de la existencia de alternativas digitales. El ticket promedio es de **\$10.180 CLP**, con una distribución fuertemente asimétrica hacia la derecha, lo que refleja la coexistencia de compras cotidianas de bajo monto junto con adquisiciones de medicamentos de alto costo asociados a tratamientos crónicos o especializados.

El modelo de regresión lineal obtuvo un R^2 ajustado de **0,1654**, explicando el 16,5 % de la variación del monto de compra. Si bien este valor es moderado, permite identificar que el porcentaje de descuento es el predictor más influyente, lo cual se interpreta como reflejo de que los tratamientos de mayor valor tienden a contar con mayor cobertura de convenios. El modelo de clustering K-Means logró una separación moderada-buena entre segmentos, con un silhouette score de **0,4719**, identificando cuatro perfiles de clientes claramente diferenciados y accionables para estrategias comerciales.

Toda operación que involucra aleatoriedad fue ejecutada con la semilla `CPYD_SEED = 7`, garantizando la reproducibilidad total de los resultados.

1. Descripción de la Solución Implementada

La solución desarrollada corresponde a una aplicación modular en Python denominada `analizar_ventas.py`, organizada en el paquete `src/cruz_morada`. El programa recibe el archivo CSV por línea de comandos, lo que permite ejecutarlo directamente desde la terminal sin modificar el código fuente:

```
CPYD_SEED=42 python3 analizar_ventas.py --csv data/ventas_completas.csv
```

El diseño sigue una arquitectura modular donde cada responsabilidad está separada en un módulo independiente, facilitando el mantenimiento, las pruebas y la extensión del sistema. El flujo general parte desde la carga del archivo, pasa por el preprocesamiento y análisis exploratorio, y culmina con la inferencia estadística.

1.1. Arquitectura del Sistema

El proyecto se organiza en los siguientes módulos principales:

Módulo	Responsabilidad
<code>configuracion.py</code>	Semilla CPYD_SEED, rutas del proyecto, constantes globales y parámetros de procesamiento
<code>carga_datos.py</code>	Carga por fragmentos (chunking) o con Dask, detección automática del separador CSV
<code>paralelo/</code>	Pool de procesos con <code>ProcessPoolExecutor</code> , particionado determinista por hash de clave
<code>preprocesamiento/</code>	Limpieza de datos, detección de outliers, creación de variables derivadas
<code>analisis_exploratorio/</code>	Estadística descriptiva, visualizaciones obligatorias, series temporales
<code>inferencia/</code>	Pruebas de hipótesis, regresión OLS, clustering K-Means

Cuadro 1: Módulos del proyecto y sus responsabilidades

1.2. Procesamiento Paralelo

El enunciado solicita paralelizar las etapas de limpieza, transformación y cálculo de estadísticos. Las tres están implementadas mediante `concurrent.futures.ProcessPoolExecutor`, manteniendo un único pool de procesos activo durante todo el pipeline para evitar el costo de crear y destruir workers repetidamente entre etapas.

El cálculo de estadísticos agregados por local siempre corre en paralelo, particionando el DataFrame por la columna `LOCAL`. La limpieza y transformación también disponen de implementación paralela (activable con `-parallel-preprocess`), pero **no se usan en paralelo por defecto**. La razón es medida, no supuesta: sobre el dataset completo de

3.242.878 filas, la versión paralela con 11 workers tardó **17,1 segundos**, mientras que la versión secuencial vectorizada tardó **7,0 segundos**, es decir, 2,4 veces más lenta. Esto ocurre porque pandas ejecuta internamente operaciones vectorizadas en C; el costo de serializar particiones entre procesos supera la ganancia de usar más núcleos para este volumen de datos.

```

1 class ParallelProcessor:
2     def __init__(self, n_workers=None):
3         self.n_workers = n_workers or N_WORKERS
4         self._executor = None
5
6     def __enter__(self):
7         if self.n_workers > 1:
8             self._executor = ProcessPoolExecutor(
9                 max_workers=self.n_workers
10            )
11         return self
12
13     def map_partitions_by_key(self, df, func, key_col,
14                             n_partitions=None, **kwargs):
15         partitions = self._split_by_hash(
16             df, key_col, n_partitions or self.n_workers
17         )
18         return self._run(func, partitions, **kwargs)

```

Listing 1: Clase ParallelProcessor (paralelo/procesador.py)

El método `map_partitions_by_key` usa hash determinista de CODIGO CLIENTE para particionar, garantizando que las transacciones de un mismo cliente nunca queden repartidas entre procesos distintos.

1.3. Reproducibilidad

Toda operación con aleatoriedad (imputación, partición train/test 70/30, inicialización de K-Means) usa la semilla fijada por la variable de entorno `CPYD_SEED = 42`, garantizando que los resultados numéricos sean totalmente deterministas entre ejecuciones, independiente del entorno donde se ejecute el programa.

Ejecución reproducible

`CPYD_SEED=42 python3 analizar_ventas.py --csv data/ventas_completas.csv`

2. Datos y Preprocesamiento

El punto de partida de cualquier análisis estadístico riguroso es garantizar la calidad de los datos sobre los que se trabaja. En este caso, el dataset entregado corresponde a un archivo único consolidado denominado `ventas_completas.csv`, que centraliza las transacciones comerciales de Cruz Morada junto con información asociada a cada

cliente. Si bien esta consolidación previa facilitó el trabajo de integración, no elimina la necesidad de revisar exhaustivamente la integridad, consistencia y coherencia de los datos antes de realizar cualquier inferencia.

2.1. Carga y Consolidación

El primer desafío encontrado fue de naturaleza técnica: el enunciado describe el archivo CSV con columnas separadas por coma, sin embargo el archivo real utiliza **punto y coma (;)** como separador y todos los campos entre comillas dobles. De no detectarse esta discrepancia, cada fila del archivo habría sido interpretada como una única columna, imposibilitando cualquier análisis posterior.

Para resolver esto de forma robusta y automática, el módulo `carga_datos.py` implementa una función de detección del separador que inspecciona la primera línea del archivo antes de proceder con la lectura completa:

```
1 def _detect_separator(csv_path):
2     opener = gzip.open if csv_path.suffix == ".gz" else open
3     with opener(csv_path, "rt", encoding="utf-8") as f:
4         header = f.readline()
5         sep = ";" if header.count(";") > header.count(",") else ","
6     return sep
```

Listing 2: Detección automática del separador CSV (`carga_datos.py`)

Dado que el archivo completo supera los 200 MB comprimidos, se implementaron dos estrategias de carga según la memoria disponible. La primera consiste en lectura por fragmentos (*chunking*), donde el archivo se procesa en bloques de 100.000 filas que se concatenan en un único DataFrame una vez finalizada la carga. La segunda activa lectura diferida con Dask mediante el flag `-dask`, útil para entornos con memoria muy limitada. En la máquina de desarrollo, con aproximadamente 2,5 GB de RAM disponibles al momento de la ejecución, la lectura por chunks resultó suficiente y más eficiente que Dask para este volumen de datos.

Por razones de privacidad y reducción de memoria, las columnas `NOMBRES` y `APELLIDOS` se descartan durante la carga, ya que no aportan información relevante para el análisis estadístico.

2.2. Valores Faltantes

Se implementó un test aproximado de MCAR (*Missing Completely At Random*) basado en la correlación entre los indicadores de ausencia de cada columna numérica, complementado con un reporte de valores nulos por columna. El resultado fue **inesperado pero consistente**: sobre los 3.242.878 registros del dataset no se encontraron valores faltantes explícitos en ninguna de las columnas. Este hallazgo difiere del ejemplo planteado en el enunciado, que sugería posibles nulos en `PORCENTAJE_DESCUENTO` y `FECHA_NACIMIENTO`.

Esto no implica que los datos estén libres de problemas, sino que los errores presentes adoptan una forma distinta a la ausencia de valores: se manifiestan como registros con valores incoherentes o fuera de rango, lo que se aborda en la sección siguiente.

2.3. Errores de Registro Detectados

Durante el proceso de limpieza se identificaron tres categorías de errores de registro que, si bien no corresponden a valores nulos, comprometen igualmente la calidad del análisis si no se tratan adecuadamente.

Problema detectado	Registros afectados	Tratamiento aplicado
BOLETA = 0 (no corresponde a documento tributario real)	8	Eliminados del dataset
PORCENTAJE DESCUENTO fuera del rango [0,1] (se encontró un registro con valor 1,17, equivalente a 117%)	1	Eliminado del dataset
EDAD implausible (negativa o superior a 100 años), originada en FECHA NACIMIENTO corrupta	3.323 (0,10 %)	Imputada con la mediana de edades plausibles (48,6 años)

Cuadro 2: Errores de registro detectados y tratamiento aplicado

Los primeros dos casos se interpretan inequívocamente como errores de digitación: una boleta con folio cero no existe en el sistema tributario chileno, y un descuento del 117 % es físicamente imposible. Por esta razón ambos fueron eliminados del análisis.

Los 3.323 registros con edad implausible presentan valores extremos como -5.944 años o 825 años, originados en fechas de nacimiento corruptas o mal ingresadas en el sistema. Dado que representan apenas el 0,10 % del total, se optó por imputar la edad con la mediana de los registros válidos (48,6 años) en lugar de eliminar las filas, preservando así las transacciones asociadas a esos clientes. El umbral de edad plausible se definió como el intervalo [0, 100] años, valor conservador documentado explícitamente en el código mediante las constantes MIN_EDAD_PLAUSIBLE y MAX_EDAD_PLAUSIBLE.

2.4. Detección de Valores Atípicos

Se aplicaron los métodos IQR (rango intercuartílico con factor 1,5) y Z-score (umbral $|z| > 3$) sobre la variable MONTO APLICADO, que es la variable continua principal del análisis:

Método	Outliers detectados	% del total
IQR ($1,5 \times \text{RIC}$)	212.493	6,55 %
Z-score ($ z > 3$)	39.973	1,23 %

Cuadro 3: Outliers detectados en MONTO APLICADO según método aplicado

A diferencia de los errores de la sección anterior, estos valores **no fueron eliminados**. La distribución de MONTO APLICADO presenta una asimetría marcada hacia la derecha (asimetría = 9,06, curtosis = 108,23), con montos que pueden alcanzar los \$226.476 CLP. Sin embargo, estas cifras son perfectamente coherentes con el contexto de negocio: una farmacia de cadena maneja tanto compras cotidianas de bajo monto como medicamentos de alto costo asociados a tratamientos oncológicos, enfermedades crónicas o especialidades médicas. Eliminar estos registros equivaldría a sesgar el análisis ignorando un segmento relevante de la operación.

Se detectó además un hallazgo de importancia para el resto del análisis: la variable UNIDADES es igual a 1 en el **100 %** de los registros. Esto revela que el dataset está estructurado a nivel de *línea de producto por boleta*, es decir, cada fila representa un producto distinto dentro de una transacción, y no la cantidad total de unidades compradas. Como consecuencia directa, UNIDADES no aporta varianza para ningún análisis estadístico, por lo que se creó la variable derivada **ITEMS POR BOLETA** como proxy real del volumen de compra por transacción.

2.5. Variables Derivadas

A partir de las variables originales del dataset se construyeron las siguientes variables derivadas, con el objetivo de enriquecer el análisis y habilitar pruebas estadísticas que no serían posibles con las columnas originales:

Variable	Definición	Media	Observación
MONTO POR UNIDAD	MONTO APLICADO / UNIDADES	\$10.180	Idéntica a MONTO APLICADO dado que UNIDADES = 1 siempre
EDAD	(FECHA – FECHA NACIMIENTO) / 365,25	49,57 años	3.323 valores implausibles imputados con mediana
FRECUENCIA COMPRA	N° de boletas distintas por CODIGO CLIENTE	4,50	Máximo observado: 97 boletas por cliente
ITEMS POR BOLETA	N° de líneas de producto por BOLETA	1,36	Proxy real de volumen de compra
HORA	Hora extraída de FECHA	—	Usada en análisis de patrones horarios
DIA SEMANA	Día de la semana extraído de FECHA	—	Usada en hipótesis H3
ES_FIN_DE_SEMANA	Sábado o domingo	—	Variable booleana para hipótesis H3

Cuadro 4: Variables derivadas creadas durante el preprocesamiento

El cálculo de FRECUENCIA COMPRA e ITEMS POR BOLETA requiere ver todas las filas de un mismo cliente o boleta de forma conjunta. Por esta razón, cuando se activa el modo de procesamiento paralelo, el particionado se realiza mediante hash determinista de CODIGO CLIENTE, garantizando que ningún cliente quede repartido entre particiones distintas y que los resultados sean idénticos a los de la versión secuencial.

3. Análisis Exploratorio Estadístico

El análisis exploratorio tiene como objetivo caracterizar el comportamiento de los datos antes de realizar cualquier inferencia formal. Esta etapa es fundamental para entender la distribución de las variables, identificar relaciones entre ellas y detectar patrones que orienten las decisiones metodológicas posteriores, como la elección entre pruebas paramétricas y no paramétricas.

3.1. Estadística Descriptiva

Las medidas de tendencia central, dispersión, asimetría y curtosis para las variables numéricas principales se presentan a continuación:

Variable	Media	Desv. Est.	Mediana	Asimetría	Curtosis
MONTO APLICADO (CLP)	\$10.180	\$14.453	\$7.662	9,06	108,23
PORCENTAJE DESCUENTO	0,3920	0,1080	0,4000	0,2968	2,85
EDAD (años)	49,57	16,71	48,60	0,2396	-0,7897
ITEMS POR BOLETA	1,36	0,7206	1,00	3,00	14,87

Cuadro 5: Estadística descriptiva de las variables numéricas principales

El ticket promedio de \$10.180 CLP presenta una brecha significativa respecto a la mediana de \$7.662 CLP, lo que anticipa una distribución con cola larga hacia la derecha. Esta diferencia indica que la mayoría de las transacciones corresponden a compras de monto moderado, pero la presencia de medicamentos de alto costo eleva el promedio por encima de lo que experimenta el cliente típico. La curtosis de 108,23 confirma una concentración de valores extremos muy superior a la de una distribución normal, lo que tendrá implicancias directas en la elección de los tests estadísticos posteriores.

3.2. Tests de Normalidad

Antes de decidir qué pruebas estadísticas aplicar, se verificó empíricamente la normalidad de las variables continuas principales mediante los tests de Shapiro-Wilk y Kolmogorov-Smirnov:

Variable	Shapiro-Wilk (p)	Kolmogorov-Smirnov (p)	¿Normal?
MONTO APLICADO	$p < 0,0001$	$p < 0,0001$	No
PORCENTAJE DESCUENTO	$p < 0,0001$	$p < 0,0001$	No

Cuadro 6: Tests de normalidad sobre las variables continuas principales

Ambas pruebas rechazan la hipótesis de normalidad con $p < 0,0001$ para las dos variables. Este resultado no es sorprendente dado lo que muestran los histogramas: tanto MONTO APLICADO como PORCENTAJE DESCUENTO tienen distribuciones claramente no gaussianas. Como consecuencia, el pipeline selecciona automáticamente correlación de Spearman en lugar de Pearson para la matriz de correlación, y cada prueba de hipótesis verifica normalidad por grupo antes de elegir entre t-test o Mann-Whitney U.

3.3. Distribución de Variables

La Figura 1 muestra la distribución de MONTO APLICADO. La concentración de transacciones en el rango de \$0 a \$30.000 CLP es evidente, con una cola muy larga que se extiende hasta los \$226.476 CLP. Este comportamiento es completamente coherente con el contexto de una farmacia: la gran mayoría de las compras corresponde a productos de uso cotidiano, mientras que una fracción menor pero significativa corresponde a tratamientos de alto costo.




Figura 1: Distribución de MONTO APLICADO. La fuerte asimetría a la derecha es consistente con el rechazo de normalidad observado en los tests de Shapiro-Wilk y Kolmogorov-Smirnov.

La Figura 2 muestra la distribución de PORCENTAJE DESCUENTO, que presenta picos pronunciados en valores discretos: aproximadamente 20 %, 35 %, 40 % y 50 %. Este patrón refleja los tramos de copago y convenio típicos del sistema de salud chileno (Fonasa, Isapre, convenios laborales), donde los descuentos están predefinidos por contrato.




Figura 2: Distribución de PORCENTAJE DESCUENTO. Los picos discretos en 20 %, 35 %, 40 % y 50 % revelan la estructura de convenios y copagos del sistema de salud chileno.

La Figura 3 ilustra un hallazgo determinante: la distribución de UNIDADES es una masa puntual en el valor 1, confirmando que el dataset está estructurado a nivel de línea de producto.




Figura 3: Distribución de UNIDADES. El valor es igual a 1 en el 100 % de los registros, confirmando que cada fila representa una línea de producto distinta dentro de una boleta.

3.4. Boxplot por Canal de Venta

La Figura 4 muestra la distribución del monto de compra desagregada por canal de venta. Las medianas son similares entre canales, pero los canales POS y WEB concentran una cantidad mayor de valores extremos, lo que refleja simplemente que tienen más volumen de transacciones. El canal CCT, con apenas 226 transacciones, debe interpretarse con cautela.




Figura 4: MONTO APLICADO por canal de venta. Las medianas son similares entre canales, pero POS y WEB concentran más valores extremos por su mayor volumen de transacciones.

3.5. Matriz de Correlación (Spearman)

Dado el rechazo de normalidad, se calculó la matriz de correlación de Spearman, más robusta ante la presencia de valores extremos.



Figura 5: Matriz de correlación de Spearman. UNIDADES aparece en blanco por ser constante. MONTO APLICADO y PORCENTAJE DESCUENTO muestran correlación positiva de 0,48.

La correlación de Spearman entre MONTO APLICADO y PORCENTAJE DESCUENTO es de **0,4827** ($p < 0,0001$). Este resultado no implica que aplicar más descuento cause mayor gasto, sino que los productos de mayor valor tienden a estar cubiertos por convenios con mayor porcentaje de cobertura. La dirección de causalidad es inversa a la que podría suponerse: es el tipo de medicamento el que determina simultáneamente el monto y el descuento.

3.6. Análisis de Asociación entre Variables Categóricas

Prueba	Estadístico	p-value	Conclusión
Chi-cuadrado: CANAL $\times$ LOCAL	$\chi^2 = 3,242,869$	$p < 0,0001$	Significativo
ANOVA: MONTO APLICADO $\sim$ CANAL	$F = 152,55$	$p < 0,0001$	Significativo

Cuadro 7: Pruebas de asociación entre variables categóricas

El test chi-cuadrado indica que la distribución de canales no es independiente del local ($p < 0,05$): algunos locales concentran proporcionalmente más ventas digitales, lo que es esperable en zonas con mayor penetración tecnológica. El ANOVA confirma dife-

rencias significativas en el monto promedio entre canales, impulsadas principalmente por los valores extremos de los canales de mayor volumen.

3.7. Patrones Temporales

Se construyó una serie de tiempo diaria con la suma de MONTO APLICADO por día, aplicando descomposición aditiva con período de 7 días y análisis ACF/PACF.




Figura 6: Descomposición estacional de ventas diarias (noviembre 2023 – diciembre 2024). Tendencia creciente sostenida y componente estacional semanal fuerte y persistente.

La descomposición revela dos patrones dominantes: una tendencia creciente sostenida durante los 13 meses analizados, y un componente estacional semanal muy marcado con picos y valles que se repiten cada 7 días. El día de mayor venta agregada fue el 2024-09-30, con una venta diaria promedio de \$84.647.048 CLP.




Figura 7: Autocorrelación (ACF) y autocorrelación parcial (PACF). Picos marcados en rezagos múltiplos de 7 confirman la estacionalidad semanal.

El gráfico ACF muestra picos persistentes en los rezagos 7, 14, 21, 28 y 35, confirmando cuantitativamente la estacionalidad semanal. El PACF indica que el rezago 7 sigue siendo el más relevante después del rezago 1, lo que tiene implicancias directas para la planificación de inventario y dotación de personal.

3.8. Distribución por Hora del Día




Figura 8: Ventas totales acumuladas por hora del día. Actividad prácticamente nula entre las 00:00 y las 07:00, con máximo absoluto a las 18:00 horas.

El perfil horario es completamente consistente con el horario de atención de una farmacia de cadena. La actividad nocturna es mínima, el volumen crece desde la apertura a las 08:00 hasta alcanzar el máximo a las 18:00 horas, consistente con el flujo de personas que salen del trabajo.

3.9. Distribución por Género




Figura 9: Distribución de EDAD por GÉNERO (1 = Masculino, 2 = Femenino). Medianas similares entre grupos, con dispersión levemente mayor en el género masculino.

Las distribuciones de edad por género son similares, con medianas cercanas a los 50 años en ambos grupos. Esta similitud sugiere que género y edad aportan información complementaria y no intercambiable para el análisis del comportamiento de compra.

4. Inferencia Estadística

La etapa de inferencia estadística tiene como objetivo ir más allá de la descripción de los datos y responder preguntas concretas sobre el comportamiento de las ventas de Cruz Morada. Para ello se validaron cinco hipótesis formales, dos de las cuales corresponden a los ejemplos propuestos en el enunciado y tres son hipótesis propias planteadas a partir de los patrones observados durante el análisis exploratorio. En todos los casos, la elección del test estadístico se condicionó a la normalidad verificada empíricamente, no se asumió a priori.

4.1. Pruebas de Hipótesis

4.1.1. H1 — Ticket promedio APP versus WEB

Hipótesis: El ticket promedio en el canal APP es mayor que en el canal WEB.

Test aplicado: Dado que ambas distribuciones rechazan normalidad (Shapiro-Wilk $p < 0,05$), se aplicó Mann-Whitney U en lugar de t-test de Welch.

Resultados:

Parámetro	Valor
Media APP	\$10.750 CLP
Media WEB	\$11.168 CLP
Estadístico Mann-Whitney U	—
p-value	0,7217

Cuadro 8: Resultados H1: ticket promedio APP vs. WEB

Interpretación: La prueba no es estadísticamente significativa ($p = 0,7217 \geq 0,05$), por lo que **no hay evidencia suficiente para afirmar que el canal APP tenga un ticket promedio mayor que WEB**. De hecho, el ticket promedio observado en WEB (\$11.168) es numéricamente superior al de APP (\$10.750), aunque esta diferencia no es estadísticamente distinguible del azar. Este hallazgo contradice la premisa del ejemplo del enunciado y se reporta así porque es lo que muestran los datos reales. Una posible explicación es que los usuarios de WEB realizan compras planificadas de mayor valor (medicamentos crónicos solicitados desde el hogar), mientras que los usuarios de APP pueden hacer compras más impulsivas pero de monto similar.

4.1.2. H2 — Porcentaje de descuento y volumen de compra

Hipótesis: El porcentaje de descuento afecta significativamente el volumen de compra por boleta.

Adaptación metodológica: Como se documentó en la sección de preprocesamiento, UNIDADES es constante e igual a 1 en el 100 % de los registros, por lo que no aporta varianza para esta prueba tal como está planteada en el enunciado. Se utilizó ITEMS POR BOLETA como variable dependiente, que sí varía y representa el número real de líneas de producto distintas por transacción.

Test aplicado: Regresión lineal simple (ITEMS POR BOLETA $\sim$ PORCENTAJE DESCUENTO).

Resultados:

Parámetro	Valor
Pendiente	0,0615
R ²	0,000085
p-value	< 0,0001

Cuadro 9: Resultados H2: regresión ITEMS POR BOLETA ~ PORCENTAJE DESCUENTO

Interpretación: La relación es estadísticamente significativa ($p < 0,05$), pero el R² de 0,000085 indica que el porcentaje de descuento explica una fracción prácticamente nula de la variación en ítems por boleta. Con más de 3 millones de registros, incluso efectos de magnitud ínfima resultan estadísticamente detectables. **En términos de negocio, el descuento aplicado no es un predictor relevante de cuántos productos distintos lleva el cliente en su boleta.**

4.1.3. H3 — Ticket promedio en fin de semana versus día de semana

Hipótesis propia: El ticket promedio difiere significativamente entre fines de semana (sábado y domingo) y días hábiles.

Motivación: El análisis exploratorio mostró una estacionalidad semanal marcada. Si el patrón temporal afecta el volumen total de ventas, es razonable preguntarse si también afecta el ticket promedio por transacción.

Test aplicado: Mann-Whitney U (ambos grupos rechazan normalidad).

Resultados:

Parámetro	Valor
Media fin de semana	\$9.134 CLP
Media día de semana	\$10.375 CLP
p-value	< 0,0001

Cuadro 10: Resultados H3: ticket promedio fin de semana vs. día de semana

Interpretación: La diferencia es estadísticamente significativa ($p < 0,05$). El ticket promedio en días hábiles es **\$1.241 CLP mayor** que en fines de semana. Una lectura de negocio plausible es que las compras de mayor valor, como el retiro de recetas médicas o medicamentos crónicos, se concentran en días de semana porque están asociadas a consultas médicas previas que ocurren en días hábiles. El fin de semana concentra compras más espontáneas y de menor monto, como analgésicos, antigripales o artículos de cuidado personal.

4.1.4. H4 — Edad del cliente y monto de compra

Hipótesis propia: La edad del cliente se correlaciona positivamente con el monto de compra.

Motivación: Es esperable que los clientes de mayor edad gasten más en medicamentos, dado que las enfermedades crónicas y los tratamientos de largo plazo son más frecuentes en personas mayores.

Test aplicado: Correlación de Pearson (se aplicó sobre EDAD, cuya distribución es más cercana a la normal que MONTO APLICADO).

Resultados:

Parámetro	Valor
Correlación de Pearson (r)	0,0495
p-value	< 0,0001

Cuadro 11: Resultados H4: correlación EDAD vs. MONTO APLICADO

Interpretación: Existe correlación positiva y estadísticamente significativa ($p < 0,05$), pero el coeficiente de 0,0495 es muy débil. La edad por sí sola explica apenas el 0,24 % de la variación del monto de compra ($r^2 = 0,0025$). Si bien la dirección del efecto es la esperada (clientes mayores gastan levemente más), la magnitud es demasiado pequeña para ser accionable de forma aislada. Esto sugiere que la edad es una variable de contexto más que un predictor fuerte del gasto.

4.1.5. H5 — Género del cliente y monto promedio de compra

Hipótesis propia: El género del cliente influye significativamente en el monto promedio de compra.

Test aplicado: ANOVA one-way, dado que se comparan más de dos grupos y se evalúa la varianza entre géneros.

Resultados:

Parámetro	Valor
Estadístico F	2.018,31
p-value	< 0,0001

Cuadro 12: Resultados H5: ANOVA MONTO APLICADO por GÉNERO

Interpretación: La diferencia es estadísticamente significativa ($p < 0,05$). Sin embargo, con más de 3 millones de registros, incluso diferencias de magnitud moderada resultan altamente significativas. Conviene revisar la magnitud absoluta de la diferencia antes de sacar conclusiones de negocio basadas solo en el p-value. El resultado confirma

que género y edad aportan información complementaria y no redundante sobre el comportamiento de compra de los clientes de Cruz Morada.

4.2. Resumen de Hipótesis

Hip.	Enunciado	Test	p-value	Resultado
H1	Ticket promedio APP > WEB	Mann-Whitney U	0,7217	No significativo
H2	% descuento afecta volumen	Regresión lineal	< 0,0001	Significativo*
H3	Ticket difiere finde vs. semana	Mann-Whitney U	< 0,0001	Significativo
H4	Edad correlaciona con monto	Pearson	< 0,0001	Significativo*
H5	Género influye en monto	ANOVA one-way	< 0,0001	Significativo

Cuadro 13: Resumen de pruebas de hipótesis. (*) Estadísticamente significativo pero con efecto de magnitud prácticamente nula.

5. Modelado Predictivo y Descriptivo

Una vez caracterizado el comportamiento de los datos y validadas las hipótesis estadísticas, se desarrollaron dos modelos complementarios: un modelo de regresión lineal para explicar el monto de compra en función de variables del negocio, y un modelo de clustering para segmentar la base de clientes según su comportamiento acumulado. Ambos modelos fueron evaluados con partición train/test 70/30 fijada por semilla, siguiendo las indicaciones del enunciado.

5.1. Modelo de Regresión Lineal (Opción A)

5.1.1. Formulación del modelo

Se modeló MONTO APLICADO como variable dependiente en función de las siguientes variables predictoras: canal de venta (CANAL), identificador del local (LOCAL), volumen de ítems por boleta (ITEMS POR BOLETA) y porcentaje de descuento aplicado (PORCENTAJE DESCUENTO). La estimación se realizó mediante Mínimos Cuadrados Ordinarios (OLS) con la librería `statsmodels`:

$$\text{MONTO APLICADO} \sim C(\text{CANAL}) + \text{LOCAL} + \text{ITEMS POR BOLETA} + \text{PORCENTAJE DESCUENTO}$$

Como se documentó en la sección de preprocesamiento, UNIDADES fue reemplazada por ITEMS POR BOLETA porque la primera es constante e igual a 1 en todos los registros, lo que produce colinealidad perfecta con el intercepto.

5.1.2. Métricas de ajuste

Métrica	Valor
R^2 ajustado	0,1654
RMSE (conjunto de prueba)	\$13.155 CLP
MAE (conjunto de prueba)	\$6.284 CLP

Cuadro 14: Métricas de ajuste del modelo de regresión OLS (test 30 %)

El modelo explica el **16,5 %** de la variación del monto de compra. El error absoluto medio de \$6.284 CLP representa aproximadamente el 62 % del ticket promedio, lo que indica que el modelo es útil para identificar tendencias agregadas pero no para predecir con precisión el monto de una transacción específica. La variable de mayor poder predictivo omitida es el producto específico comprado (SKU), cuya altísima cardinalidad lo hace inviable en OLS.

5.1.3. Coeficientes e interpretación

Variable	Coeficiente	p-value
Intercepto (APP, referencia)	-12.531,1	< 0,0001
CANAL = POS	+1.608,5	< 0,0001
CANAL = WEB	+1.057,7	< 0,0001
CANAL = CCT	-611,2	0,5700
LOCAL	-0,1287	< 0,0001
ITEMS POR BOLETA	-64,23	< 0,0001
PORCENTAJE DESCUENTO	+54.569,7	< 0,0001

Cuadro 15: Coeficientes e interpretación del modelo OLS

El coeficiente más influyente es PORCENTAJE DESCUENTO (+\$54.570), confirmando que los productos de mayor valor tienden a contar con mayor cobertura de convenio. Los canales POS y WEB tienen tickets significativamente más altos que APP (\$1.609 y \$1.058 respectivamente), mientras que CCT no muestra diferencia significativa ($p = 0,570$) por su volumen reducido. El coeficiente negativo de ITEMS POR BOLETA indica que a mayor número de productos distintos en la boleta, menor es el monto promedio por ítem.

5.1.4. Detección de multicolinealidad (VIF)

Variable	VIF	Evaluación
LOCAL	1,30	Sin problema ($VIF < 5$)
ITEMS POR BOLETA	3,71	Sin problema ($VIF < 5$)
PORCENTAJE DESCUENTO	3,82	Sin problema ($VIF < 5$)

Cuadro 16: Factor de inflación de varianza (VIF) para los predictores numéricos

Ningún VIF supera el umbral de 5, por lo que no hay evidencia de multicolinealidad severa entre los predictores retenidos en el modelo.

5.1.5. Diagnóstico de supuestos

Todo modelo OLS descansa sobre tres supuestos fundamentales: linealidad, homocedasticidad y normalidad de los residuales.




Figura 10: Residuos vs. valores ajustados (muestra de 5.000 puntos). El patrón en forma de abanico es evidencia visual de heterocedasticidad.




Figura 11: Q-Q plot de residuales (muestra de 5.000 puntos). Los puntos se apartan de la recta en ambas colas, confirmando que los residuales no son normales.

Test	Supuesto evaluado	p-value	Conclusión
Breusch-Pagan	Homocedasticidad	< 0,0001	Heterocedástico
Jarque-Bera	Normalidad de residuales	< 0,0001	No normales

Cuadro 17: Tests formales de diagnóstico de supuestos del modelo OLS

Los supuestos clásicos de OLS quedan comprometidos. El gráfico de residuos vs. ajustados muestra un patrón en forma de abanico que confirma heterocedasticidad: el error de predicción crece a medida que aumenta el monto estimado. El test de Jarque-Bera confirma que los residuales no son normales, con asimetría de 7,50 y curtosis de 82,07. Esto significa que los p-valores reportados son aproximados y probablemente subestiman la incertidumbre real para transacciones de alto monto, aunque no invalida las conclusiones cualitativas del modelo.

5.2. Modelo de Clustering K-Means (Opción B)

5.2.1. Construcción del modelo

Se segmentó la base de clientes de Cruz Morada usando cuatro variables agregadas por CODIGO CLIENTE: monto total gastado, total de ítems comprados, número de transacciones distintas y descuento promedio recibido. Las variables fueron estandarizadas con `StandardScaler` antes de aplicar K-Means (semilla 7), entrenado sobre el 70 % de los clientes y evaluado sobre el 100 %.

5.2.2. Elección del número de clústeres




Figura 12: Método del codo para elegir k ($k=2$ a $k=8$). Mayor cambio de pendiente entre $k=3$ y $k=5$. Se eligió $k=4$ por ser el número más interpretable y accionable para el negocio.

La curva del método del codo no presenta un quiebre único y evidente. El mayor cambio de pendiente ocurre entre $k = 3$ y $k = 5$, por lo que se eligió $k=4$. Esta elección combina criterio matemático y criterio de negocio: 4 segmentos es un número manejable para diseñar campañas comerciales diferenciadas.

5.2.3. Métricas de validación

Métrica	Valor
Silhouette score ($k=4$)	0,4719
Inercia WCSS ($k=4$)	1.139.648

Cuadro 18: Métricas de validación del modelo K-Means con $k=4$

Un silhouette score de 0,4719 indica una separación moderada-buena entre los cuatro segmentos: son razonablemente distinguibles entre sí, lo que es esperable en un dataset de comportamiento de clientes con distribución continua y asimétrica.

5.2.4. Perfil de cada clúster

Clúster	N° clientes	%	Monto total	Ítems	Transacc.	Desc. prom.
3 (Alto valor)	28.356	2,4 %	\$238.197	13,4	9,7	0,40
0 (Medio-alto)	237.076	20,0 %	\$63.177	5,8	5,1	0,40
1 (Moderado)	707.196	59,8 %	\$13.662	1,7	1,5	0,40
2 (Bajo compromiso)	210.613	17,8 %	\$7.686	1,4	1,3	0,20

Cuadro 19: Perfil de cada clúster en unidades originales (no estandarizadas)

Los cuatro segmentos presentan perfiles claramente diferenciados:

- **Clúster 3 — Alto valor (2,4 %):** Clientes con mayor gasto total (\$238.197), casi 10 transacciones y más de 13 ítems acumulados. Representan el segmento prioritario para programas de fidelización dado su peso desproporcionado en ingresos.
- **Clúster 0 — Medio-alto (20,0 %):** Gasto promedio de \$63.177 con frecuencia moderada. Candidatos a campañas de up-selling o recordatorios de reposición de medicamentos crónicos.
- **Clúster 1 — Moderado (59,8 %):** El segmento más numeroso, con gasto moderado (\$13.662) y baja frecuencia (1,5 transacciones en promedio). Base de clientes ocasionales con acceso a convenios.
- **Clúster 2 — Bajo compromiso (17,8 %):** Menor gasto (\$7.686) y el descuento promedio más bajo de los cuatro (0,20), lo que sugiere clientes sin convenio activo o con acceso limitado a programas de beneficios. Representa una oportunidad de incorporación a programas básicos de fidelización.

5.2.5. Extrapolabilidad y limitaciones del modelo

Ambos modelos fueron evaluados con partición train/test 70/30. Sin embargo, es importante señalar las limitaciones de extrapolación:

- **Ventana temporal limitada:** El dataset cubre 13 meses. La tendencia creciente observada podría no sostenerse y el modelo no la captura explícitamente.
- **Variable de producto omitida:** El predictor más relevante del monto (SKU) no fue incluido por su altísima cardinalidad.
- **LOCAL como variable numérica:** Es un identificador, no una magnitud, por lo que su coeficiente lineal no tiene interpretación directa de negocio.
- **Sesgo de canal:** CCT representa apenas 226 transacciones (0,01 %). Las estimaciones para este canal son poco confiables.
- **Clustering sensible a clientes ocasionales:** Una fracción relevante de clientes realizó solo 1 transacción, lo que influye en la forma de los clústeres.

6. Justificación de Técnicas y Librerías

Una decisión metodológica bien fundamentada es tan importante como el resultado numérico que produce. En esta sección se explica el razonamiento detrás de cada elección técnica realizada durante el análisis, respondiendo no solo qué se usó sino por qué se prefirió esa alternativa por sobre otras igualmente disponibles.

6.1. Justificación de las Técnicas Estadísticas

6.1.1. Detección de outliers: IQR y Z-score en lugar de DBSCAN

El enunciado permite aplicar IQR, Z-score o DBSCAN para la detección de valores atípicos. Se optó por los dos primeros porque el objetivo era caracterizar la cola de una única variable continua (`MONTO APLICADO`), tarea para la cual IQR y Z-score son métodos estándar, computacionalmente baratos sobre 3,24 millones de filas, y fáciles de justificar con un umbral explícito y documentado.

DBSCAN es más apropiado para detectar outliers multivariados, es decir, combinaciones inusuales entre varias variables simultáneamente. Aquí el interés era univariado: ¿qué montos son atípicamente altos o bajos en relación al resto? Para esa pregunta, IQR y Z-score son más directos y transparentes. Además, DBSCAN requiere calibrar dos hiperparámetros (`eps` y `min_samples`) que no tienen valores obvios para datos de ventas, lo que habría introducido subjetividad innecesaria.

6.1.2. Selección automática entre Pearson/Spearman y t-test/Mann-Whitney

En lugar de asumir normalidad y aplicar siempre las mismas pruebas, el pipeline verifica empíricamente la distribución de cada grupo antes de decidir qué test usar. Si el grupo sigue una distribución normal (Shapiro-Wilk $p > 0,05$), se aplican Pearson y Welch t-test. Si no, se aplican Spearman y Mann-Whitney U.

Esta decisión tiene una consecuencia práctica inmediata: dado que `MONTO APLICADO` rechaza normalidad de forma contundente en todos los subgrupos, prácticamente todas las pruebas de comparación de medias terminan usando versiones no paramétricas. Estas son más robustas ante la presencia de outliers de cola larga como los que presenta este dataset, y no asumen ninguna distribución subyacente.

6.1.3. Chi-cuadrado para asociación entre variables categóricas

Se usó chi-cuadrado para evaluar la independencia entre `CANAL` y `LOCAL` porque ambas son variables categóricas y la pregunta es de independencia, no de diferencia de medias. La prueba evalúa si la distribución de canales observada en cada local es consistente con lo que se esperaría si canal y local fueran independientes. Para comparaciones de monto entre categorías (ANOVA, Mann-Whitney) se usaron los tests correspondientes a variables numéricas.

6.1.4. Regresión OLS en lugar de modelos de árboles o regularización

Se eligió regresión lineal múltiple por OLS porque el enunciado pide explícitamente “interpretación de coeficientes y R^2 ajustado”, no maximizar el poder predictivo puro. OLS entrega coeficientes con signo, magnitud y p-value directamente interpretables en las unidades originales de negocio (pesos chilenos), lo que permite decir cosas concretas como “las transacciones en POS tienen un ticket \$1.655 mayor que en APP, controlando por el resto de las variables”.

Un modelo de árboles como Random Forest o Gradient Boosting habría dado probablemente un RMSE menor, pero a costa de perder esa interpretabilidad directa. Ridge o Lasso habrían sido útiles si hubiera multicolinealidad severa, pero los VIFs calculados muestran que no la hay. La elección de OLS no es una simplificación sino la respuesta correcta al objetivo planteado.

6.1.5. K-Means en lugar de clustering jerárquico o DBSCAN

Con más de 1,18 millones de clientes distintos en el dataset, el clustering jerárquico es computacionalmente inviable sin muestrear agresivamente: requiere calcular una matriz de distancias de tamaño $O(n^2)$, lo que en este caso implicaría manejar más de 10^{12} pares. En la máquina de desarrollo esto produjo un tiempo de ejecución de 13 minutos con uso de CPU prácticamente nulo, señal de que el sistema estaba en *swapping* de memoria. Al agregar `sample_size=10.000` la misma operación bajó a 21 segundos.

DBSCAN requiere calibrar `eps` y `min_samples` sin garantizar un número estable de clústeres, lo que dificulta la interpretación de negocio y la comparación entre ejecuciones. K-Means, en cambio, escala linealmente con el número de puntos, produce un número de segmentos elegido explícitamente y ese número puede justificarse con el método del codo más el silhouette score, dando un resultado directamente accionable: 4 campañas diferenciadas para 4 segmentos de clientes.

6.1.6. Breusch-Pagan y Jarque-Bera para diagnóstico de la regresión

Son los tests estándar de la literatura econométrica para evaluar homocedasticidad y normalidad de residuales respectivamente, ambos disponibles directamente en `statsmodels` y computacionalmente baratos incluso sobre el conjunto de entrenamiento completo de más de 2 millones de filas. Su elección no requiere supuestos adicionales más allá de tener el modelo OLS ya ajustado, lo que los hace adecuados para este contexto.

6.1.7. Partición train/test 70/30 con semilla fija

Es la proporción que especifica explícitamente el enunciado. Se aplicó de forma consistente tanto a la regresión como al clustering (70 % para entrenar K-Means, evaluación

de silhouette sobre el 100 % de los clientes), con la semilla CPYD_SEED = 42 garantizando que la partición sea idéntica entre ejecuciones.

6.2. Justificación de las Librerías Utilizadas

La elección de cada librería responde a criterios concretos de disponibilidad, rendimiento y adecuación al problema, no a preferencias arbitrarias.

Librería	Justificación de uso
<code>pandas</code>	Librería estándar de facto para manipulación tabular en Python. Permite lectura por chunks para manejar archivos grandes sin agotar la memoria, y sus operaciones vectorizadas en C son más rápidas que los equivalentes en Python puro para este volumen de datos.
<code>NumPy</code>	Soporte numérico de bajo nivel para operaciones vectorizadas de respaldo. Usada internamente por <code>pandas</code> , <code>scipy</code> y <code>scikit-learn</code> , y directamente para operaciones de muestreo reproducible con semilla fija.
<code>Dask</code>	Alternativa a <code>pandas</code> para lectura diferida en entornos con memoria muy limitada. Se activa con <code>-dask</code> y permite procesar el archivo sin cargarlo completamente en RAM. No se usa por defecto porque para este volumen <code>pandas</code> en chunks es más eficiente.
<code>SciPy</code>	Implementa todas las pruebas estadísticas utilizadas: Shapiro-Wilk, Kolmogorov-Smirnov, Pearson, Spearman, t-test de Welch, Mann-Whitney U, ANOVA y chi-cuadrado. Es la librería de referencia para estadística científica en Python.
<code>statsmodels</code>	Permite ajustar modelos OLS con sintaxis de fórmulas tipo R (<code>smf.ols</code>), lo que facilita la inclusión de variables categóricas con la notación <code>C(CANAL)</code> . También implementa los tests de diagnóstico de regresión (Breusch-Pagan, Jarque-Bera), el cálculo de VIF y la descomposición estacional y ACF/PACF para series temporales.
<code>scikit-learn</code>	Implementa K-Means, <code>StandardScaler</code> , <code>train_test_split</code> y las métricas de evaluación (RMSE, MAE, <code>silhouette score</code>). Es la librería estándar de machine learning en Python, con implementaciones optimizadas y reproducibles mediante semilla.
<code>matplotlib</code> / <code>seaborn</code>	Generación de todas las visualizaciones del informe: histogramas con curva de densidad, boxplots por categoría, matriz de correlación como heatmap, series de tiempo y gráfico del método del codo. <code>Seaborn</code> simplifica la creación de gráficos estadísticos sobre <code>pandas DataFrames</code> con una línea de código.
<code>concurrent.futures</code>	Librería estándar de Python para procesamiento paralelo con <code>ProcessPoolExecutor</code> . Se prefirió sobre alternativas como <code>multiprocessing</code> directamente porque su interfaz de alto nivel (<code>submit</code> , <code>as_completed</code>) facilita el manejo de resultados ordenados y el control de errores por partición. Al ser parte de la librería estándar, no requiere instalación adicional.

Cuadro 20: Librerías utilizadas y justificación de su elección

7. Dificultades Encontradas y Soluciones

El desarrollo de este trabajo no estuvo exento de obstáculos técnicos y metodológicos. A continuación se documentan las dificultades más relevantes encontradas durante el proceso, junto con la forma en que fueron detectadas y resueltas. Esta sección refleja el proceso real de trabajo y no solo el resultado final.

7.1. Separador incorrecto en el archivo CSV

Problema: El enunciado describe el archivo CSV con columnas separadas por coma, sin embargo el archivo real utiliza punto y coma (;) como separador y todos los campos entre comillas dobles. De no detectarse esta discrepancia, cada fila habría sido interpretada como una única columna, imposibilitando cualquier análisis posterior.

Cómo se detectó: Al intentar leer el archivo con el separador por defecto de pandas (coma), el DataFrame resultante tenía una sola columna con todo el contenido de cada fila concatenado. La inspección manual de las primeras líneas del archivo confirmó el uso de punto y coma.

Solución: Se implementó una función de detección automática del separador en `carga_datos.py` que inspecciona la primera línea del archivo antes de proceder con la lectura completa. La función compara la frecuencia de coma y punto y coma en el encabezado y selecciona el más frecuente, haciéndola robusta ante futuros cambios en el formato del archivo.

7.2. Cálculo de silhouette score inviable sin muestreo

Problema: El cálculo del silhouette score sobre todos los clientes del dataset intentaba construir una matriz de distancias de tamaño $O(n^2)$ entre más de 1,18 millones de clientes, lo que resultó computacionalmente inviable.

Cómo se detectó: Una corrida de prueba con aproximadamente 300.000 clientes tardó 13 minutos con uso de CPU prácticamente nulo, señal inequívoca de que el sistema estaba transfiriendo datos entre RAM y disco (*swapping*) en lugar de calcular.

Solución: Se agregó el parámetro `sample_size=10.000` con semilla fija (`CPYD_SEED = 42`) a la función `silhouette_score` de scikit-learn. Esto redujo el tiempo de cálculo a aproximadamente 21 segundos, manteniendo la reproducibilidad y produciendo una estimación estadísticamente representativa del score real sobre la población completa de clientes.

7.3. Variable UNIDADES constante en todo el dataset

Problema: La variable UNIDADES, que el enunciado sugiere usar como indicador del volumen de compra, resultó ser igual a 1 en el 100 % de los 3.242.878 registros. In-

cluirla como predictor en la regresión producía colinealidad perfecta con el intercepto, haciendo que la matriz de diseño no fuera invertible y que los coeficientes resultantes fueran idénticos entre el intercepto y UNIDADES.

Cómo se detectó: Los estadísticos descriptivos mostraban desviación estándar igual a 0 para UNIDADES, y una corrida preliminar de la regresión devolvió coeficientes degenerados con advertencias de singularidad de la matriz.

Solución: Se documentó el hallazgo como una característica estructural del dataset (el archivo está a nivel de línea de producto, no de cantidad total por compra) y se creó la variable derivada ITEMS POR BOLETA como proxy real del volumen de compra por transacción. Esta variable sí tiene varianza y se usó en su reemplazo en la regresión y en la hipótesis H2.

7.4. Edades implausibles por fechas de nacimiento corruptas

Problema: El campo FECHA NACIMIENTO contenía 3.323 registros con valores corruptos que generaban edades calculadas completamente incoherentes, como valores negativos de hasta $-5,944$ años o superiores a 825 años.

Cómo se detectó: Los estadísticos descriptivos de la variable EDAD mostraban un mínimo de $-5,944$ años y un máximo de 825 años, valores que son físicamente imposibles y delataron inmediatamente la presencia de fechas mal ingresadas en el sistema de origen.

Solución: Se definió un rango plausible de edad entre 0 y 100 años, documentado explícitamente en el código mediante las constantes MIN_EDAD_PLAUSIBLE y MAX_EDAD_PLAUSIBLE. Los registros fuera de este rango fueron imputados con la mediana de las edades válidas (48,6 años), preservando las transacciones asociadas a esos clientes en lugar de eliminarlas.

7.5. Incompatibilidad de scipy.stats.kstest

Problema: Al ejecutar el test de Kolmogorov-Smirnov mediante `scipy.stats.kstest` pasando los parámetros de la distribución como argumentos posicionales junto al string "norm", se produjo un error de tipo `TypeError` en la primera corrida con datos reales.

Cómo se detectó: La excepción fue capturada durante la primera ejecución completa del pipeline sobre el dataset real, luego de que las pruebas unitarias con datos sintéticos no reprodujeran el error porque usaban muestras más pequeñas con una versión diferente del parámetro.

Solución: Se reemplazó la llamada por una distribución “congelada” (*frozen distribution*) de scipy, construyendo explícitamente el objeto `stats.norm(loc=media, scale=desviacion).cdf` y pasándolo directamente como función de distribución acumulada al test. Esta forma es más explícita y compatible entre versiones de scipy.

7.6. Procesamiento paralelo más lento que el secuencial

Problema: Al implementar la limpieza y transformación de variables en paralelo con `ProcessPoolExecutor`, el tiempo de ejecución fue de **17,1 segundos** con 11 workers, mientras que la versión secuencial vectorizada tomó **7,0 segundos**, es decir, la versión paralela fue 2,4 veces más lenta.

Cómo se detectó: Se midieron directamente los tiempos de ambas versiones sobre el dataset completo de 3.242.878 filas, con y sin el flag `-parallel-preprocess`.

Solución: Se analizó la causa raíz: las operaciones de limpieza y transformación en pandas son internamente vectorizadas en C, por lo que el cuello de botella no es el cómputo sino la serialización (*pickling*) de particiones grandes entre procesos. Cuando el costo de comunicación supera la ganancia de paralelismo, agregar más workers empeora el rendimiento en lugar de mejorarlo. Se tomó la decisión de usar procesamiento secuencial por defecto para estas etapas, manteniendo la implementación paralela disponible como opción (`-parallel-preprocess`) para volúmenes de datos donde el trabajo por partición sea suficientemente pesado como para amortizar el costo de comunicación. El cálculo de estadísticos por local sí corre en paralelo por defecto, ya que ese caso involucra operaciones de agrupamiento más costosas que sí se benefician del paralelismo.

7.7. Restricción de memoria en la máquina de desarrollo

Problema: La máquina de desarrollo disponía de aproximadamente 2,5 GB de RAM libres al momento de ejecutar el pipeline completo, lo que representaba una restricción real para un dataset de más de 200 MB comprimidos que al expandirse en memoria ocupa significativamente más espacio.

Cómo se detectó: Monitoreo activo del uso de memoria antes y durante la ejecución completa del pipeline.

Solución: Se tomaron dos medidas complementarias. Primero, las columnas `NOMBRES` y `APELLIDOS` se descartan durante la carga del CSV, ya que son datos de identificación personal que no se usan en ningún análisis y su eliminación reduce la huella de memoria del DataFrame. Segundo, se implementó el flag `-dask` como alternativa de lectura diferida para entornos con memoria más restringida, aunque en este caso la lectura por chunks de pandas resultó suficiente y más eficiente.

8. Conclusiones

El presente trabajo abordó el análisis estadístico completo de 3.242.869 transacciones válidas de la cadena de farmacias Cruz Morada, correspondientes a 13 meses de operación continua entre noviembre de 2023 y diciembre de 2024. A lo largo del proceso se recorrieron todas las etapas de un pipeline de análisis de datos riguroso: desde la

carga y limpieza del archivo hasta la construcción de modelos predictivos y descriptivos, pasando por un análisis exploratorio exhaustivo y la validación formal de hipótesis estadísticas.

8.1. Hallazgos Principales

Los resultados obtenidos permiten extraer conclusiones concretas y accionables para la toma de decisiones en Cruz Morada:

El canal presencial sigue siendo absolutamente dominante. El canal POS concentra el 96,19 % de las transacciones, mientras que los canales digitales (WEB y APP) juntos no alcanzan el 4 %. Esto no necesariamente refleja una preferencia de los clientes por la atención presencial, sino también la realidad de que muchas farmacias del universo analizado pueden no tener habilitados los canales digitales o tenerlos con funcionalidad limitada. En cualquier caso, existe un espacio considerable para el crecimiento de los canales digitales sin canibalizar el canal presencial.

El ticket promedio está fuertemente sesgado por medicamentos de alto costo. La mediana de \$7.662 CLP es notablemente inferior a la media de \$10.180 CLP, lo que revela que la mayoría de las transacciones son de monto moderado pero una fracción de compras de alto valor (tratamientos oncológicos, crónicos, especializados) eleva artificialmente el promedio. Esto tiene implicancias directas para el diseño de estrategias de pricing y para la interpretación de cualquier métrica basada en el promedio simple.

El descuento refleja el tipo de medicamento, no el comportamiento del cliente. La correlación positiva entre porcentaje de descuento y monto de compra (0,41) no implica que el descuento genere mayor gasto. La relación causal es inversa: los medicamentos de mayor valor tienden a estar cubiertos por convenios con mayor porcentaje de cobertura. Esta distinción es fundamental para evitar conclusiones erróneas en el diseño de políticas comerciales.

Las ventas presentan estacionalidad semanal fuerte y tendencia creciente. El análisis de series de tiempo confirmó que el día de la semana es un factor determinante en el nivel de ventas, con picos marcados y persistentes en los rezagos múltiples de 7 en la función de autocorrelación. Simultáneamente, se observa una tendencia creciente sostenida durante los 13 meses analizados, lo que sugiere que Cruz Morada experimentó crecimiento real en su volumen de ventas durante el período.

El ticket promedio en días hábiles es significativamente mayor que en fines de semana. La hipótesis H3 confirmó una diferencia de \$1.241 CLP entre ambos grupos ($p < 0,0001$). Las compras de mayor valor, asociadas a retiro de recetas médicas y tratamientos crónicos, se concentran en días hábiles porque están ligadas a consultas médicas previas. Esta información es útil para la planificación de inventario y dotación de personal diferenciada por día de la semana.

El modelo de clustering identifica cuatro segmentos accionables. El análisis de K-Means con $k=4$ (silhouette = 0,4691) produjo segmentos claramente diferenciados:

un grupo de alto valor (2,4 % de los clientes, monto promedio \$238.092), un grupo medio-alto (20,0 %, \$63.130), un grupo moderado que constituye la mayoría de la base (59,8 %, \$13.659) y un grupo de bajo compromiso con el menor descuento promedio de los cuatro (17,8 %, \$7.680, descuento 0,20). El segmento de alto valor es el candidato prioritario para campañas de fidelización, mientras que el segmento de bajo compromiso representa una oportunidad de incorporación a programas de beneficios básicos.

8.2. Sobre el Modelo de Regresión

El modelo de regresión OLS explicó el 16,4 % de la variación del monto de compra (R^2 ajustado = 0,1639), con un MAE de \$6.281 CLP en el conjunto de prueba. Este resultado es honesto: el modelo identifica correctamente las variables que influyen en el monto y la dirección de su efecto, pero su poder predictivo puntual es limitado porque el predictor más relevante (el producto específico comprado) no fue incluido por razones de cardinalidad. Los supuestos clásicos de OLS no se cumplen plenamente: el modelo es heterocedástico y los residuales no son normales, lo que indica que los p-values reportados son aproximados. Esta limitación no invalida las conclusiones cualitativas pero desaconseja usar el modelo para predicción puntual sin correcciones adicionales.

8.3. Sobre el Procesamiento Paralelo

Una de las lecciones más importantes de este trabajo fue que paralelizar no siempre implica ir más rápido. La implementación paralela de las etapas de limpieza y transformación resultó 2,4 veces más lenta que la versión secuencial, porque el costo de serializar y transferir particiones grandes entre procesos superó la ganancia de usar más núcleos. El procesamiento paralelo es efectivo cuando el trabajo por partición es suficientemente pesado; en este caso, las operaciones vectorizadas de pandas ya son internamente paralelas en C y no se benefician de un paralelismo adicional a nivel de proceso. Esta distinción es importante para cualquier implementación futura sobre volúmenes de datos mayores.

8.4. Reflexión Final

El análisis realizado demuestra que los datos de ventas de Cruz Morada contienen información valiosa para la toma de decisiones comerciales, pero que extraerla requiere un proceso riguroso de validación, limpieza y análisis que no puede reemplazarse por la simple lectura de promedios superficiales. El hallazgo de que UNIDADES es constante en todo el dataset, de que el separador del CSV difiere del enunciado, o de que las edades implausibles distorsionan el análisis demográfico, son ejemplos concretos de que los datos reales siempre presentan sorpresas que solo emergen cuando se los examina con detenimiento.

La reproducibilidad total garantizada por `CPYD_SEED = 42` asegura que todos los resultados presentados en este informe pueden ser verificados y replicados exactamente con el código entregado, ejecutando:

```
CPYD_SEED=42 python3 analizar_ventas.py --csv data/ventas_completas.csv
```

9. Bibliografía

- McKinney, W. (2017). *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython* (2.a ed.). O'Reilly Media.
- VanderPlas, J. (2016). *Python Data Science Handbook: Essential Tools for Working with Data*. O'Reilly Media.
- Géron, A. (2019). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* (2.a ed.). O'Reilly Media.
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning with Applications in R* (2.a ed.). Springer.
- Wooldridge, J. M. (2019). *Introductory Econometrics: A Modern Approach* (7.a ed.). Cengage Learning.
- Montgomery, D. C., Peck, E. A., & Vining, G. G. (2021). *Introduction to Linear Regression Analysis* (6.a ed.). Wiley.
- Hastie, T., Tibshirani, R., & Friedman, J. (2017). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2.a ed., 12.a impresión). Springer.
- Bruce, P., Bruce, A., & Gedeck, P. (2020). *Practical Statistics for Data Scientists: 50+ Essential Concepts Using R and Python* (2.a ed.). O'Reilly Media.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Seabold, S., & Perktold, J. (2010). Statsmodels: Econometric and Statistical Modeling with Python. *Proceedings of the 9th Python in Science Conference (SciPy 2010)*, 57–61.
- Hunter, J. D. (2007). Matplotlib: A 2D Graphics Environment. *Computing in Science & Engineering*, 9(3), 90–95.
- Waskom, M. (2021). Seaborn: Statistical Data Visualization. *Journal of Open Source Software*, 6(60), 3021.
- Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., ... & Oliphant, T. E. (2020). Array Programming with NumPy. *Nature*, 585, 357–362.
- Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau,

- D., ... & SciPy 1.0 Contributors. (2020). SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python. *Nature Methods*, 17, 261–272.
- Rocklin, M. (2015). Dask: Parallel Computation with Blocked Algorithms and Task Scheduling. *Proceedings of the 14th Python in Science Conference (SciPy 2015)*, 130–136.